Décisions collective et multicritère

Rendu du projet de fin de semestre

Compléter une playlist en utilisant une méthode ELECTRE IS

Félix de Batz

Année 2025 - 2026

Table des matières

1 Introduction **2**
- 1.1 Objectif de l'analyse . . . 2
- 1.2 Informations disponibles . . . 2
- 1.3 Résultat attendu . . . 2

2 Méthodologie **2**
- 2.1 Restriction de l'analyse . . . 2
- 2.2 Définition des critères . . . 2
- 2.3 Définition des variables et des fonctions . . . 3
  - 2.3.1 Les ensembles . . . 3
  - 2.3.2 Les fonctions associées aux caractéristiques . . . 4
  - 2.3.3 Les fonctions associées au profil de la playlist . . . 4
  - 2.3.4 Les fonctions associées aux scores des musiques . . . 5
- 2.4 Prépartion des donnéees . . . 5
  - 2.4.1 Détermination du profil de la playlist . . . 5
  - 2.4.2 Tri préliminaire musiques recommendables . . . 7
  - 2.4.3 Calcul des scores de toutes les musiques recommendables . . . 7
- 2.5 Mise en place de la méthode de surclassement . . . 7
  - 2.5.1 Création des matrices de concordance . . . 7
  - 2.5.2 Création de la relation de surclassement . . . 8
- 2.6 Recherche des solutions . . . 8
  - 2.6.1 Réduction du graphe de relation . . . 8
  - 2.6.2 Recherche du noyau du graph . . . 8

3 Mise en pratique **9**
- 3.1 Détermination du spectre d'analyse et récupération de l'information . . . 9
  - 3.1.1 Résumé des musiques enregistrées . . . 9
- 3.2 Traitement préliminaire des données . . . 9
  - 3.2.1 Création du profil de la playlist . . . 10
  - 3.2.2 Calcul des scores des musiques . . . 10
- 3.3 Mise en place de la méthode de surclassement . . . 10
  - 3.3.1 Création des matrices de concordance . . . 10
  - 3.3.2 Création du graphe de surclassement . . . 11
- 3.4 Recherche des solutions . . . 11
  - 3.4.1 Comparaison des données et du profil de la playlist . . . 12
  - 3.4.2 Comparaison de R^* et du profil de la playlist . . . 12

4 Limites du modèle **16**

5 Conclusion **16**

6 Annexes **17**
- 6.1 Graphiques . . . 17
  - 6.1.1 Répartion des musiques utilisées par critère . . . 17
  - 6.1.2 Détail du profil de la playlist . . . 21
  - 6.1.3 Détail de la répartition des scores . . . 25
  - 6.1.4 Détail des matrices de concordances . . . 27

1 Introduction

En 2021, Spotify a lancé une nouvelle fonctionnalité, *Enrichir* qui permet à un utilisateur de compléter sa playlist par des musiques que *Spotify* considère comme similaires à celles déjà présentes. Aujourd'hui la fonctionnalité a évolué pour devenir *Aléatoire intelligent (Smart Shuffle)* mais l'idée reste la même, pouvoir recommander à un utilisateur de nouvelles musiques à découvrir en fonction de celles qu'il écoute déjà. Nous cherchons aujourd'hui à recréer un système similaire en utlisant des méthodes de décisions multricritérielles.

1.1 Objectif de l'analyse

On cherche à compléter la playlist d'un utilisateur de manière cohérente, selon les titres déjà présents. L'objectif de cette analyse est de trouver, pour une playlist donnée, les musiques qui pourraient y être ajoutées de manière à préserver l'esthétique de la playlist.

1.2 Informations disponibles

Afin de nous aider à déterminer les musiques qui pourraient être ajoutées, nous avons accès à l'ensemble des caractéristiques principales des musiques (tempo, genre, année de sortie, etc). Ces informations sont facilement accessibles depuis internet.

1.3 Résultat attendu

L'analyse doit permettre de recommander à l'utilisateur un certain nombre de musiques qui devraient lui plaire et qui ne sont pas déjà dans sa playlist.

2 Méthodologie

2.1 Restriction de l'analyse

Il faudrait théoriquement analyser l'ensemble des musiques existantes pour trouver celles qui correspondraient à la playlist. Ceci n'étant pas réaliste, nous limiterons nos musiques recommandables à une préselection R. De plus, nous simplifierons très légèrement les caractéristiques des musiques, beaucoup de caractéristiques sont définies par un nombre réel entre 0 et 1. Pour faciliter notre analyse, nous les transformerons en nombre entier entre 0 et 100.

2.2 Définition des critères

Pour caractériser une musique il existe une grande variété de paramètres. Nous avons décidé d'analyser qu'un sous-ensemble de ces caractéristiques, en sélectionnant les plus pertinentes. Voici un tableau récapitulatif des différents critères utilisés.

Critère	**Valeurs possibles**	**Signification**
Tempo	$\mathbb{N}$	Vitesse de la musique (plus la valeur est élevée, plus la musique est rapide).
Valence	$[\![0, 100]\!]$	Positivité émotionnelle (faible : mélancolique, élevée : joyeuse).
Énergie	$[\![0, 100]\!]$	Intensité perçue (faible : calme, élevée : dynamique).
Instrumentalité	$[\![0, 100]\!]$	Part instrumentale (faible : beaucoup de paroles, élevée : principalement instrumentale).
Style	$P(S)$	Genre musical associé (Pop, Rock, Electro, etc.).
Année	$\mathbb{N}$	Année de sortie de la musique.
Popularité	$[\![0, 100]\!]$	Niveau de notoriété du titre (faible : peu conu, élevée : extrémement connu).

TABLE 1 – Récapitulatif des critères utilisés lors l'analyse

2.3 Définition des variables et des fonctions

Pour plus de clarté nous définissons ici le nom des variables et des fonctions auxquels nous ferons référence dans le document.

2.3.1 Les ensembles

Nom	**Dénomination**
Espace des musiques	$\mathbb{M}$
Ensemble des musiques constituant la Playlist	$P \subset \mathbb{M}$
Ensemble des musiques recommandables	$R \subset M$
Ensemble des musiques recommandables filtré	$R' = R \setminus P$
Ensemble des styles musicaux	$S = \{Rap, Pop, Jazz, Rock, \ ...\}$
Ensemble des critères utilisés	$Cr = \{Tempo, Valence, Energie, Instru, Style, Année, Popularité\}$
Valeurs possibles pour chaque critère	$E_{cr} \subset \mathbb{R} \quad \forall\, cr \in Cr$

TABLE 2 – Récapitulatif des ensembles utilisés

2.3.2 Les fonctions associées aux caractéristiques

Nom	**Dénomination**
Tempo	$base_{Tempo} : \mathbb{M} \to \mathbb{N}$
Valence	$base_{Valence} : \mathbb{M} \to [\![0, 100]\!]$
Énergie	$base_{Energie} : \mathbb{M} \to [\![0, 100]\!]$
Instrumentalité	$base_{Instru} : \mathbb{M} \to [\![0, 100]\!]$
Style	$base_{Style} : \mathbb{M} \to P(S)$
Année	$base_{Année} : \mathbb{M} \to \mathbb{N}$
Popularité	$base_{Popularité} : \mathbb{M} \to [\![0, 100]\!]$

TABLE 3 – Récapitulatif des fonctions utilisées pour caractériser une musique

2.3.3 Les fonctions associées au profil de la playlist

Nom	**Dénomination**
Profil du tempo	$prof_{Tempo} : \mathbb{N} \to [0, 1]$
Profil de la valence	$prof_{Valence} : [\![0, 100]\!] \to [0, 1]$
Profil de l'énergie	$prof_{Energie} : [\![0, 100]\!] \to [0, 1]$
Profil de l'instrumentalité	$prof_{Instru} : [\![0, 100]\!] \to [0, 1]$
Profil du Style	$prof_{Style} : S \to [0, 1]$
Profil de l'année	$prof_{Année} : \mathbb{N} \to [0, 1]$
Profil de la popularité	$prof_{Popularité} : [\![0, 100]\!] \to [0, 1]$

TABLE 4 – Récapitulatif des fonctions utilisées pour représenter le profil d'une playlist

2.3.4 Les fonctions associées aux scores des musiques

Nom	**Dénomination**
Score sur le tempo	$g_{Tempo} : \mathbb{M} \to [0,1]$
Score sur la valence	$g_{Valence} : \mathbb{M} \to [0,1]$
Score sur l'énergie	$g_{Energie} : \mathbb{M} \to [0,1]$
Score sur l'instrumentalité	$g_{Instru} : \mathbb{M} \to [0,1]$
Score sur le style	$g_{Style} : \mathbb{M} \to \mathbb{R}^+$
Score sur l'année	$g_{Année} : \mathbb{M} \to [0,1]$
Score sur la popularité	$g_{Popularité} : \mathbb{M} \to [0,1]$

TABLE 5 – Récapitulatif des fonctions utilisées pour représenter les scores d'une musique

2.4 Prépartion des donnéees

Au début de notre analyse nous considérons que nous avons un panel de $R \cup P$ musiques. Pour chaque musique m, nous avons leurs différentes caractéristiques $cr \in Cr$ définies par les fonctions $base_{cr}(m)$. Pour mener à bien notre analyse nous devons d'abord transformer ces données brutes pour les formater afin qu'elle soient exploitables. Cela signifie, que pour chaque musique nous devons avoir un indicateur de performance correspondant à chaque critère. Pour cela nous allons procéder en 2 étapes, d'abord déterminer le profil de la playlist sur chaque critère, puis y comparer toutes nos musiques afin d'en déduire leurs scores, correspondant à leur proximité avec le profil de la playlist.

2.4.1 Détermination du profil de la playlist

Dans un premier temps nous devons définir le profil de la playlist fournie. Pour cela nous devons séparer les caractéristiques en deux catégories, la première concerne les caractéristiques continues, cela engloble le Tempo, la Valence, l'Énergie, l'Instrumentalité, l'Année et la Popularité, la deuxième catégorie, les critères discrets qui ne comprends que le Style.

1re catégorie :
Pour représenter le profil de la playlist sur le critère $c_r \in Cr \setminus \{Style\}$ nous allons déterminer pour chaque valeur x du critère sa proximité avec la playlist. Nous pourrions prendre le nombre moyen d'occurrences de la valeur : $\frac{|\{m \in P \,/\, base_{cr}(m) = x\}|}{|P|}$.
Mais cela pose problème dans certains cas. Prenons un exemple : si notre playlist contient 100 morceaux, 50 ont un tempo de 100 et les 50 autres ont un tempo de 110. Alors une musique recommandable avec un tempo de 105 aurait un score de 0, ce qui serait contre-intuitif.
Nous voulons donc qu'une valeur donne également du poid aux valeurs proches, autrement dit nous voulons lisser la courbe des valeurs. Pour ce faire nous allons créer une fonction pour chaque musique m de $P : G^0_{\mu,\sigma} : \mathbb{R} \to [0,1]$. Elle est définie comme la fonction de répartition d'une loi gaussienne $\mathcal{N}(\mu, \sigma)$ centrée sur $\mu = base_{cr}(m)$. σ est fixé pour chaque critère de manière arbitraire afin de garantir une pente suffisament douce pour lisser les valeurs sans trop harmoniser l'ensemble. Nous sommons ensuite toutes ces fontions et normalisons pour obtenir

la valeur du profil, ce qui donne la formule :

$$\forall\, x \in \mathbb{R} \quad G^0_{\mu,\sigma}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$$

$$\forall\, x \in E_{cr} \quad prof_{c_r}(x) = \frac{1}{|P|}\sum_{m\in P} G^0_{\mu,\sigma}(x) \quad où \quad \mu = base_{cr}(m) \quad et \quad \sigma = \frac{max(E_{cr}) - min(E_{cr})}{45}$$

Cependant, cette méthode introduit deux problèmes. Premièrement, elle défavorise les valeurs aux bords de l'ensemble, deuxièmement les écarts entre les valeurs dépendent fortement de la taille de l'ensemble, ce qui compliquera plus tard la mise en place de seuils d'indifférences et de préférences.
Pour résoudre le premier problème, nous pouvons imaginer que la fonction $G^0_{\mu,\sigma}$ rebondisse sur le bord plutôt que d'être perdue. Pour modéliser cet effet nous ajoutons deux fonctions similaires, l'une symétrique par rapport à la borne inférieure $x_{inf} = inf(E_{cr})$, que nous nommerons $G^1_{\mu,\sigma} : \mathbb{R} \to [0,1]$ et l'autre par raport à la borne supérieur $x_{sup} = max(E_{cr})$), nommée $G^2_{\mu,\sigma} : \mathbb{R} \to [0,1]$

$$\forall\, x \in E_{cr} \quad G^1_{\mu,\sigma} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x-(2x_{inf}-\mu)}{\sigma}\right)^2\right)$$

$$\forall\, x \in E_{cr} \quad G^2_{\mu,\sigma} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x-(2x_{sup}-\mu)}{\sigma}\right)^2\right)$$

Enfin pour accentuer les écarts entre les valeurs nous appliquons une fonction $MinMax : E_{cr} \to [0,1]$. Elle transpose nos valeurs dans l'espace [0,1] en associant 1 à la plus grande et 0 à la plus petite, on la défnie comme ceci.

$$\forall\, x \in E_{cr} \quad MinMax(x) = \frac{x - x_{inf}}{x_{max} - x_{inf}}$$

Ainsi pour le critère c_r nous obtenons la formule suivante :

$$\forall\, x \in E_{cr} \quad prof_{c_r}(x) = MinMax(\frac{1}{|P|}\sum_{m\in P} G^3_{c_r(m),\sigma}(x)) \quad où \quad \sigma = \frac{max(E_{cr}) - min(E_{cr})}{45}$$

avec

$$G^3_{\mu,\sigma} = G^0_{\mu,\sigma} + G^1_{\mu,\sigma} + G^2_{\mu,\sigma}$$

Ainsi, nous pouvons définir de cette manière le profil pour le tempo, la valence, l'énergie, l'instrumentalité, l'année ainsi que la popularité.

2nd catégorie :

Pour le style musical, nous ne pouvons pas appliquer la même logique, il faut le traiter de manière discrète. Nous faisons simplement la moyenne, nous traiterons l'écart possible entre les genres lors du calcul des scores des musiques.

$$\forall\, x \in S \quad prof_{Style}(x) = \frac{1}{|P|}\sum_{m\in P} base_{Style}(m)$$

Nous avons alors caractérisé notre playlist et défini son profil. Il faut maintenant comparer l'ensemble des musiques recommandables à ce profil.

2.4.2 Tri préliminaire musiques recommendables

Avant commencer l'analyse des musiques disponibles, nous pouvons déjà retirer celles que nous sommes certains de pas recommander, celles déjà présentes dans la playlist. On pose donc R' cet ensemble, défni de la manière suivante :

$$R' = R \setminus P$$

2.4.3 Calcul des scores de toutes les musiques recommendables

Nous pouvons maintenant commencerà calculer pour toutes les musiques un score pour chacun de leurs critères. Ce score représente la proximité de la musique avec la playlist sur le critère désigné. Le travail effectué dans la création du profil de la playlist facilite énormément cette étape. Pour un critère $c_r \in Cr \setminus \{Sty\}$ et une musique donnée $m \in R'$, nous regardons la valeur du critère $base_{cr}(m)$ et nous prenons la valeur associée sur le profil de playlist $prof_{c_r}$. Nous obtenons alors la définition :

$$\forall\, c_r \in Cr \setminus \{Sty\} \quad \forall\, m \in R' \quad g_{c_r}(m) = prof_{c_r}(base_{c_r}(m))$$

Pour les styles musicaux, le travail doit être un peu plus subtil. En effet nous avons naturellement envie de dire qu'une musique de pop est plus proche d'une playlist de rap qu'une musique classique. Il nous faut donc déterminer une proximité entre les styles. Pour plus de simplicité, nous définirons de telles distances entre 0 et 1, 0 signifiant qu'il s'agit du même style et 1 des styles parfaitement opposés.

$$styleProx : S \times S \to [0, 1]$$

Ainsi on peut définir le score de style d'une musique $m \in R'$ par rapport à la playlist P comme suit :

$$\forall\, m \in R' \quad g_{Style}(m) = \frac{1}{|S|} \sum_{s \in S} \sum_{g \in St(m)} styleProx(s, g) \times prof_{Style}(s)$$

Pour rappel, $St(m)$ renvoi l'ensemble des genres musicaux auxquels apartient la musique, d'où l'utlisation de la double somme. Nous noterons qu'il s'agit du seul score qui puisse être plus grand que 1 théoriquement. Cependant au vu de l'exceptionnelle rareté qu'un tel cas représenterait, nous décidons de ne pas normaliser par la somme des distances ce qui permet de créer des écarts plus grands entre les scores.
Nous avons donc maintenant tous les éléments pour commencer l'analyse et déterminer les musiques les plus pertinentes à ajouter à la playlist.

2.5 Mise en place de la méthode de surclassement

L'objectif de notre analyse est d'extraire un sous ensemble de musique à ajouter à la playlist. Il s'agit d'un problème de choix, nous utiliseront donc la méthode ELECTRE IS qui nous permettra de définir une relation de surclassement unique que l'on représentera sous la forme d'un graphe orienté. Suite à quoi nour chercherons dans ce graphe le sous ensemble de solutions dominantes.

2.5.1 Création des matrices de concordance

Dans un premier temps, nous devons définir pour chaque critère la matrice de concordance associée. Pour calculer la concordance entre deux musiques $m_1, m_2 \in R'$ sur le critère $cr \in Cr$ nous utiliserons la formule suivante.

$$c_{cr}(m_1, m_2) = \begin{cases} 1 & g_{cr}(m_2) - q_{cr} \leq g_{cr}(m_1), \\ 0 & g_{cr}(m_1) \leq g_{cr}(m_2) - p_{cr}, \\ \dfrac{g_{cr}(m_1) + p_{cr} - g_{cr}(m_2)}{p_{cr} - q_{cr}} & sinon. \end{cases} \quad (1)$$

Où q_{cr} et p_{cr} représentent respectivement les seuils d'indifférence et de préférence liés à chaque critère.

Enfin, nous pouvons calculer notre matrice de concordance globale en sommant les matrices associées à chaque critère et pondérées par w_{cr}, les poids de chaque critère. Ainsi, la concordance globale $C : R' \times R' \to [0, 1]$ entre deux musiques $m_1, m_2 \in R'$ s'écrit :

$$\forall\, m_1, m_2 \in R' \quad C(m_1, m_2) = \sum_{j \in Cr} c_j(m_1, m_2) w_j$$

2.5.2 Création de la relation de surclassement

Nous avons maintenant définit la concordance entre deux musiques, pour créer une relation de surclassement sur nos musiques recommendable, S, nous utliserons un seuil $s \in [0, 1]$ et nous définirons notre relation comme suit :

$$\forall\, m_1, m_2 \in R', \quad m_1 S m_2 \iff C(m_1, m_2) > s$$

Nous représentons la relation par un graphe orienté $G = (R', E)$ avec,

$$(m_1, m_2) \in E \iff m_1 S m_2$$

2.6 Recherche des solutions

L'ensemble des musique à recommander $R^* \subset R'$ de notre graphe doit suivre deux propriétés fondamentales. R^* doit être dominant et ne pas posséder d'éléments qui domineraient un autre élément de R^*. Ces deux propriétés se formalisent ainsi :

$$\forall\, m_1 \in R' \setminus R^*, \exists\, m_2 \in R^* \quad / \quad m_2 S m_1$$

$$\forall\, m_1, m_2 \in R^* \quad \neg(m_1 S m_2)$$

Cependant l'existence et l'unicité d'un tel ensemble n'est pas encore garantie. Il faut pour cela rendre notre graphe acyclique.

2.6.1 Réduction du graphe de relation

Nous pouvons faire l'hypothèse raisonnable de considérer que les musiques qui se dominent mutuellement par transivité, sont équivalentes. Cela correspond aux composantes fortement connexes de notre graphe.
Nous identifions les composantes fortement connexes à l'aide d'un algorithme de Kosaraju, puis nous les réduisons en fusionnant leurs sommets. Nous obtenons donc un graphe orienté acyclique.

2.6.2 Recherche du noyau du graph

Maintenant que notre graphe est acyclique, nous pouvons rechercher R^*. Pour cela nous utilisons un algorithme glouton de recherche de noyau. Nous obtenons enfin notre sélection de musiques à ajouter à la playlist de l'utilisateur $R*$.

3 Mise en pratique

Le but de cette partie est de mettre en application la méthodologie théorique discutée plus haut. L'entierté du code a été rédigé en python et les parties principales sont disponibles en annexes de ce document.

3.1 Détermination du spectre d'analyse et récupération de l'information

Avant toute chose, il nous faut définir notre périmètre de recherche. Nous décidons arbitrairement de n'étudier que les styles suivants :

$$S = \{Rap, Pop, Jazz, Rock, Classique, Métal, Variété française, Latino, Electronique\}$$

Nous fixons également $E_{Année} = [\![1950, 2025]\!]$ et $E_{Tempo} = [\![40, 250]\!]$ comme les années et les tempos possibles. Nous pouvons maintenant trouver les musiques qui constitueront la base de notre échantillon en respectant ces critères. Pour cela nous allons nous appuyer sur l'API *Spotify* ainsi que sur l'API *ReccoBeats*. La première nous servira à scanner les playlists pour y récupérer les différentes musiques ainsi que les styles associés à l'artiste. La deuxième servira à trouver les caractéristiques musicales des morceaux.

3.1.1 Résumé des musiques enregistrées

La liste complète des musiques utilisées est disponible en annexe, elle est composée de 2884 morceaux uniques. Pour un aperçu général, les graphiques de l'annexe *Répartion des musiques utilisées par critère* représente la répartition des musiques sur chaque critère. Cette liste a été constituée en récupérant ces différentes playlists disponibles de manière publique sur *Spotify* :

- LA meilleure playlist rap fr
- Jazz Greates Hits
- Best Classical Musics
- Best Electronic Music Of All Time
- Best latino Hits of All times
- Best Rock songs of All time
- Le meilleur du Metal
- Variété française 60-70-80-90-2000
- Best hits of all time

Certaines musiques ont du être omises car elles n'étaient pas reconnues par l'API de *ReccoBeats* ou certaines de leurs caractéristiques étaient inconues. Enfin, pour la playlist P à compléter, nous avons sélectionné une de nos playlists existantes composée de 131 musiques.

- Voiture #3

Toutes les informations ont été enregistrées dans deux fichiers CSV (*allMusicData.csv* et *thePlaylistData.csv*) disponibles en annexes.
Les fonctions utilisées pour récolter les données sont définies dans le fichier Python *recupData.py*

3.2 Traitement préliminaire des données

Maintenant que nous pouvons charger toutes nos musiques depuis un fichier CSV, il nous faut les préparer pour l'anlayse.

3.2.1 Création du profil de la playlist

Nous avons défini un objet UserTaste qui possède en attribut des listes représentant les fonctions $prof_{cr}$ pour tous les critères $cr \in Cr$. Elles ont été initialisées en utilisant les fonctions décrites dans la partie théorique. Le code associé se trouve au sein du fichier *createUserTasteAndScores.py*. Pour avoir un aperçu du profil généré par rapport aux données brutes, l'ensemble des graphiques est disponible en annexe *Détail du profil de la playlist*.

3.2.2 Calcul des scores des musiques

Pour commencer, nous retirons l'ensemble des musiques déjà présentes dans notre playlist, cela nous laisse 2877 titres à analyser. Nous cherchons à calculer le score de chaque musique $m \in R'$ pour tous les critères, c'est-à-dire la proximité avec la playlist. Pour tous les scores hors style musical, nous pouvons prendre la valeur associée $base_{cr}$ au critère $cr \in Cr$ depuis la liste de UserTaste. Pour les styles musicaux en revanche, nous définissons cette matrice de proximité entre les genres.

Style	**Rap**	**Pop**	**Jazz**	**Rock**	**Class.**	**Métal**	**Var. Fra.**	**Latino**	**Electro**
Rap	1.0	0.7	0.5	0.4	0.2	0.3	0.6	0.7	0.6
Pop	0.7	1.0	0.6	0.7	0.4	0.3	0.8	0.7	0.7
Jazz	0.5	0.6	1.0	0.5	0.6	0.2	0.5	0.6	0.5
Rock	0.4	0.7	0.5	1.0	0.3	0.7	0.6	0.5	0.5
Classique	0.2	0.4	0.6	0.3	1.0	0.4	0.5	0.4	0.4
Métal	0.3	0.3	0.2	0.7	0.4	1.0	0.3	0.2	0.4
Var. Fra.	0.6	0.8	0.5	0.6	0.5	0.3	1.0	0.7	0.6
Latino	0.7	0.7	0.6	0.5	0.4	0.2	0.7	1.0	0.6
Electro	0.6	0.7	0.5	0.5	0.4	0.4	0.6	0.6	1.0

TABLE 6 – Matrice de proximité entre les styles musicaux (1 = identique, 0 = opposé)

À défaut de trouver une source complète sur le sujet cette matrice à été définie arbitrairement.

Nous pouvons maintenant déterminer le score du genre musical pour chaque musique par rapport à la playlist.

Nous avons désormais pour chaque musique sa proximité avec la playlist sur les différents critères. La répartition des scores par critères est disponible dans l'annexe Détail de la répartition des scores.
Le code qui a permis de déterminer les scores de chaque musique est disponible dans le fichier *createUserTasteAndScores.py*.

3.3 Mise en place de la méthode de surclassement

3.3.1 Création des matrices de concordance

Pour définir la fonction de concordance, les seuils d'indifférence (q_{cr}), de préférence (p_{cr}) et les poids (w_{cr}) de chaque critère ont été définis. Les seuils ont été déterminés après une analyse des courbes de scores obtenus par plusieurs panels de musiques face à différentes playlists afin de représenter les écarts ou les similarités entre les musiques le plus justement possible. Les poids ont été fixés d'après les résultats obtenus par différentes batteries de tests afin d'obtenir les valeurs les plus cohérentes possible et que leur somme soit égale à 1.

Critère	*Tempo*	*Valence*	*Energie*	*Instru*	*Style*	*Année*	*Popularité*
q_{cr}	0.02	0.02	0.02	0.02	0.02	0.02	0.02
p_{cr}	0.3	0.3	0.3	0.3	0.3	0.3	0.3
w_{cr}	0.15	0.05	0.15	0.1	0.2	0.1	0.15

TABLE 7 – Matrice des seuils (indifférence et préférence) et poids des critères

Nous pouvons maintenant définir les matrices de surclassement pour chaque critère Mat_{cr}.

$$\forall\, cr \in Cr \quad \forall\, m_1, m_2 \in R' \quad Mat_{cr}[m_1, m_2] = c_{cr}(m_1, m_2)$$

Ainsi la matrice de suclassement global est :

$$Mat_C = \sum_{cr \in Cr} w_{cr}\, Mat_{cr}$$

Nous avons alors notre matrice synthétisant la performance de chaque musique par rapport à toutes les autres. L'entièreté du code utilisé pour génerer ces matrices est disponible au sein du fichier *createConcordanceMatrices.py*. De plus, vous trouverez dans l'annexe *Détail des matrices de concordances* la distribution des valeurs au sein des matrices de concordance. Pour une analyse plus pousée, sont également disponibles les *HeatMap* de chaque matrice, représentant la totalité de la matrice en transformant les valeurs en couleur.

3.3.2 Création du graphe de surclassement

Maintenant que nous avons nos performances de chaque musique, il faut déterminer à partir de quel seuil peut-on considérer qu'une matrice domine une autre. Nous avons fixé ce seuil à $s = 0.9$. Ce seuil très élevé à première vu est justifié par de nombreux tests qui nous ont orientés à choisir un seuil aussi haut. Nous avons trouvé plusieurs facteurs qui expliqueraient ce seuil, premièrement les seuils de préférence sont très élevés, ce qui donne à l'ensemble de la matrice des valeurs très hautes. De plus, nous cherchons à drastiquement réduire l'espace de nos solutions, nous visons une recommandation d'une dizaine de muiques, à partir d'un ensemble de presque 3000 possibilités.
Une fois ce seuil fixé, il est facile de créer le graphe directionnel correspondant à la relation de surclassement. Notre graphe est composé de 2877 sommets et de 1 223 483 arcs.
Le code de la modélisation du graphe est disponible dans le fichier *models.py* et celui de sa création dans *graphHandler.py*

3.4 Recherche des solutions

Pour trouver le noyau du graphe, nous devons d'abord réduire ses composantes connexes afin d'obtenir un graphe acyclique. Pour cela nous avons implémenté l'algorithme de Kosaraju de manière itérative afin d'éviter les erreurs de récurrence. Nous pouvons désormais réduire ces composantes connexes en 1 sommet en fusionnant le nom des musiques. Le graphe réduit possède 253 sommets et 7206 arcs, ce qui est une réduction très importante signifiant que un grand nombre de musiques étaient équivalentes entre elles. Le code de la réduction du graphe est disponible dans le fichier *graphHandler.py*.

3.4.1 Comparaison des données et du profil de la playlist

Nous pouvons enfin lancer notre algorithme de recherche du noyau R^* sur le graphe réduit.
Dans ce cas, nous pouvons recommander 13 musiques :

- APA - Mora
- Am I Wrong - Nico Vinz
- Villa sur la côte - Laylow
- Con Altura - ROSALÍA
- Send Me on My Way - Rusted Root
- 92i veyron - Booba
- Girls Like You (feat. Cardi B) - Cardi B Version - Maroon 5
- Nique les clones, Pt. II - Nekfeu
- Johnny, Johnny - Jeanne Mas
- La Modelo - Ozuna
- Weak - AJR
- 60 années - Damso
- Me Gusta - Shakira

À première vue, ces musiques correspondent plutôt bien au style de la playlist. Analysons plus en détail les différences entre les musiques retenues et le profil de la playlist.

3.4.2 Comparaison de R^* et du profil de la playlist

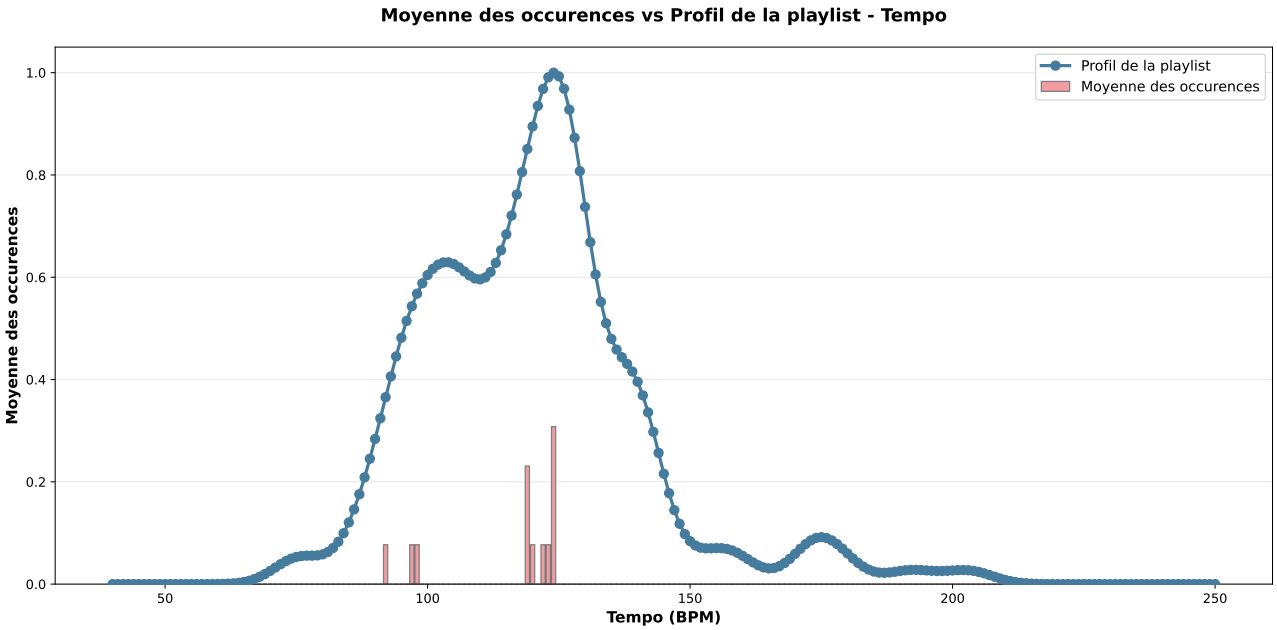


FIGURE 1 – Comparaison entre les musiques recommandées et le profil de la playlist sur le tempo

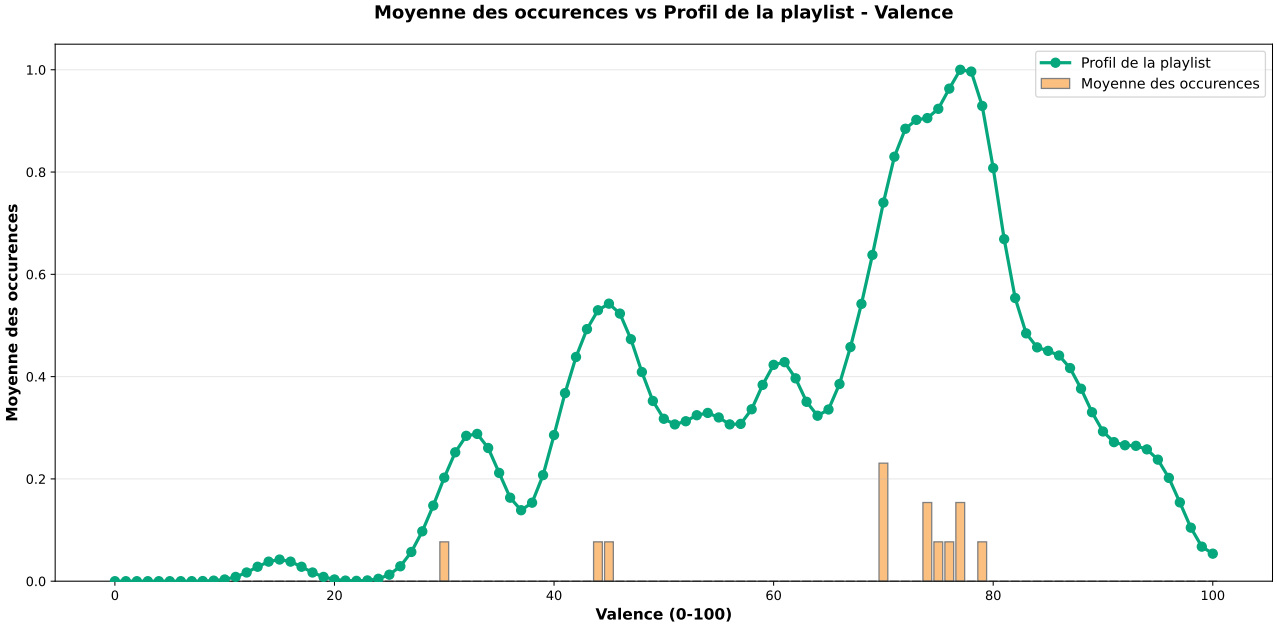


FIGURE 2 – Comparaison entre les musiques recommandées et le profil de la playlist sur la valence

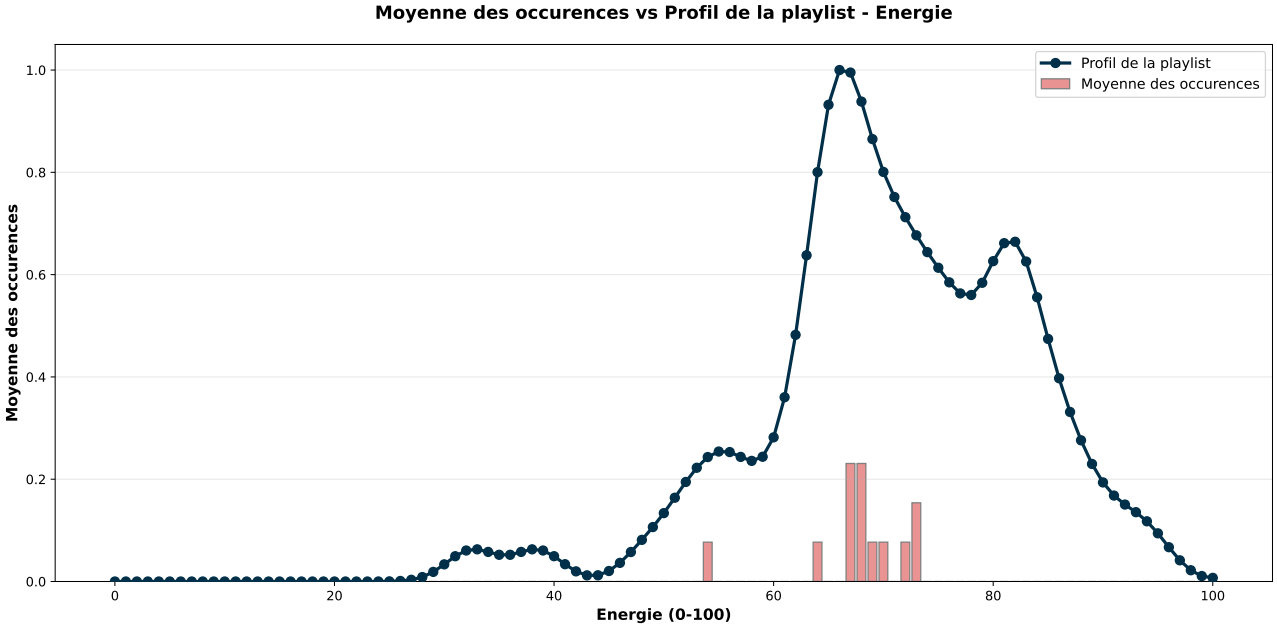


FIGURE 3 – Comparaison entre les musiques recommandées et le profil de la playlist sur l'énergie

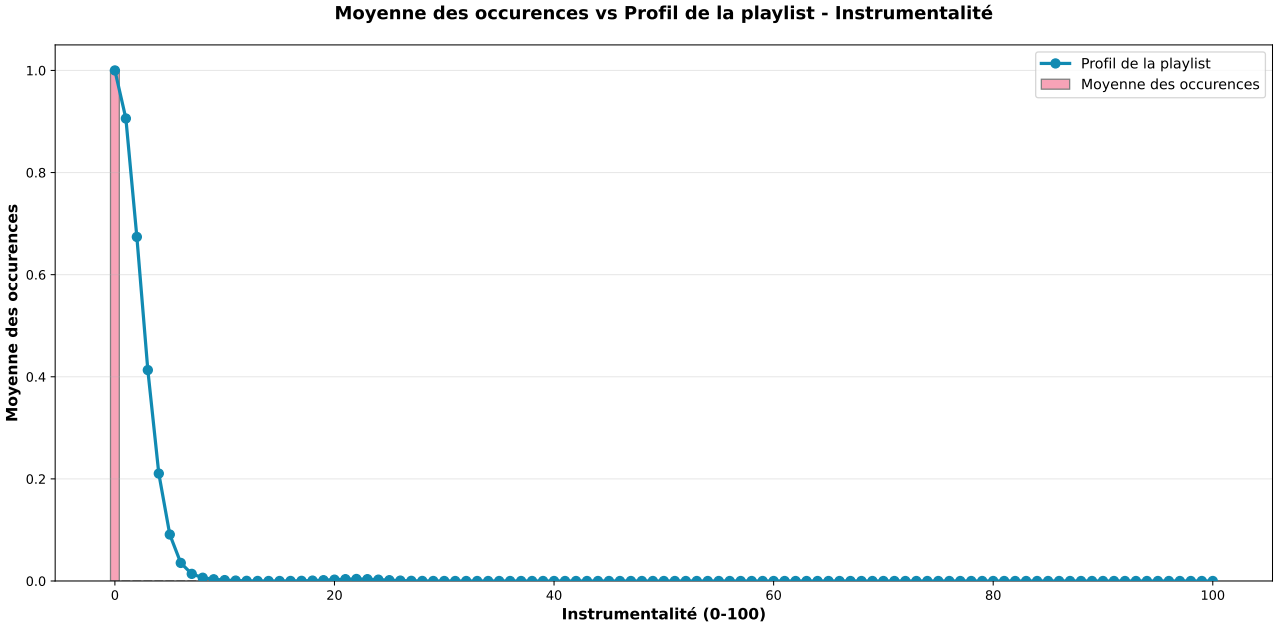


FIGURE 4 – Comparaison entre les musiques recommandées et le profil de la playlist sur l'instrumentalité

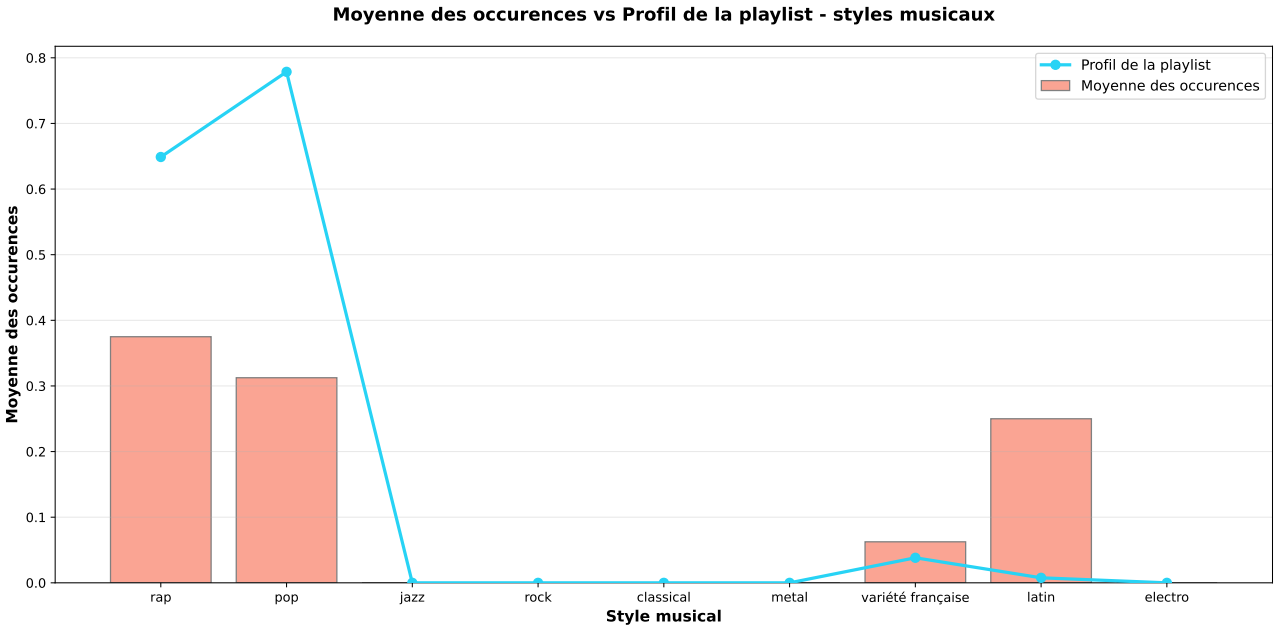


FIGURE 5 – Comparaison entre les musiques recommandées et le profil de la playlist sur le style musical

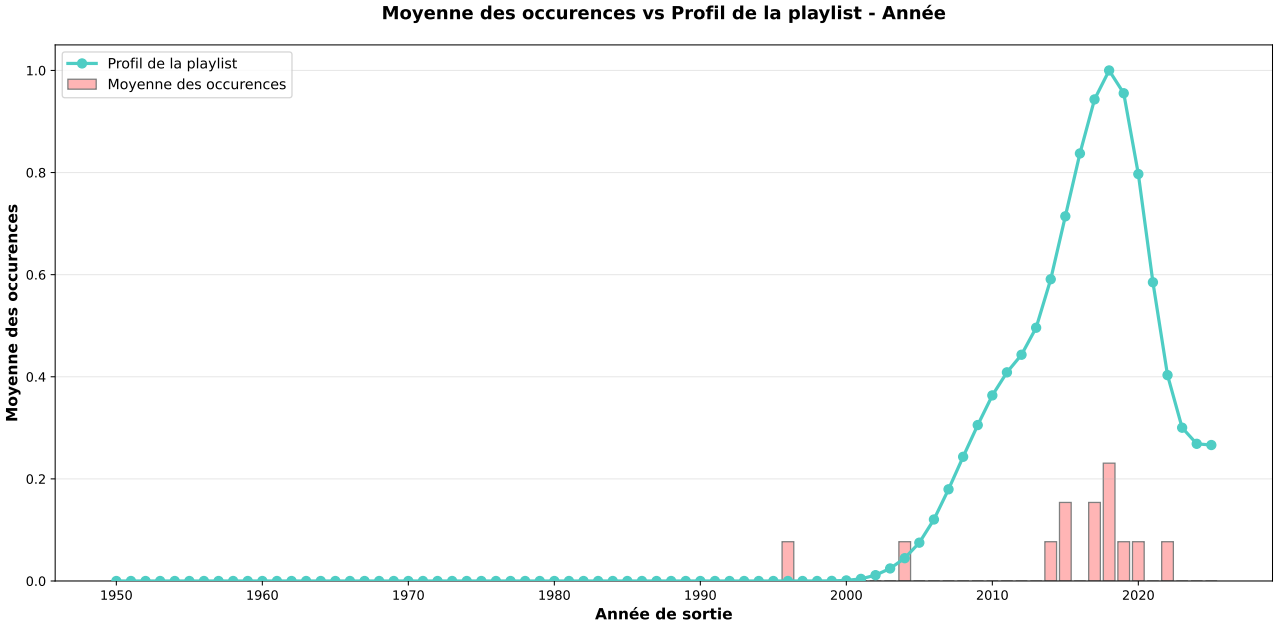


FIGURE 6 – Comparaison entre les musiques recommandées et le profil de la playlist sur l'année

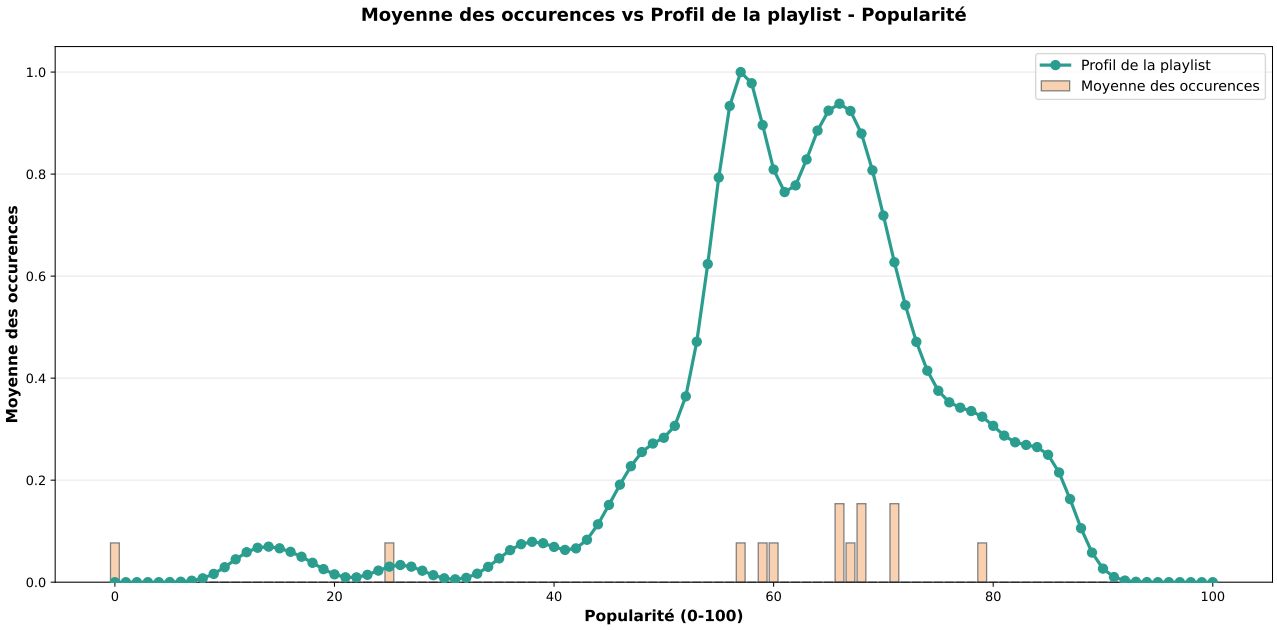


FIGURE 7 – Comparaison entre les musiques recommandées et le profil de la playlist sur la popularité

Ces graphiques sont les plus importants de notre analyse. Ils nous permettent de mesurer si nos recommandations sont en adéquation avec les musiques déjà présentes. Pour la plupart des critères, nous observons une très forte corrélation entre le profil et les musiques sélectionnées. Par exemple, pour le tempo, l'énergie ou la valence, les musiques recommandées tombent pile dans les pics du profil.

Le seul critère qui n'est pas très bien respecté est le style musical, cela fait écho aux scores obtenus par les musiques sur ce critère qui étaient tous très proches (cf Répartition des scores des musiques filtrées pour le style musical). Il est plus compliqué d'avoir des concordances pertinentes. Ce qui se traduit finalement par une contrainte moins rigide sur ce critère et donc des résultats plus éloignés de la cible.

4 Limites du modèle

La méthode que nous avons utilisée pour arriver à ce résultat pose plusieurs problèmes et présente un certain nombre de limites.

Premièrement, le modèle possède beaucoup de simplifications qui nuise à sa performance. Nous ne nous sommes concentrés que sur un nombre extrêmement restreint de genres musicaux, omettant entièrement l'existence de sous-genres. Ensuite la sélection des critères a été faite de manière à préserver la faisabilité de l'étude mais cela nuit à la pertinence et à la finesse des résultats finaux. Pour améliorer notre analyse il faudrait considérer tous les genres musicaux et les sous-genres, il faudrait également définir des critères à partir des fichiers musicaux directement pour ne plus être limité au nombre restreint de caractéristiques offert par les API classiques.

Deuxièmement, le nombre de paramètres à fixer de manière exogène est très important. De la manière dont est créer le profil de la playlist au seuil de domination, de nombreuses décisions ont du être prises avec un impact très important sur les résultats finaux. Si les paramètres et fonctions actuellement en place ont permis d'avoir un résultat cohérent dans notre cas, nous n'avons aucune garantie qu'ils seront aussi pertinents pour l'ensemble des playlists et bases de données initiales. Cela rend l'extension de cette méthode compliquée et incertaine.
Par exemple l'augmentation du nombre de styles musicaux considérés impacterait grandement la fonction score de ce critère, ce qui aurait pour conséquence de réduire les écarts entre les scores des musiques. Elles auraient toutes des scores extrêmement faibles.

Enfin, le temps de calcul devient vite très couteux. La complexité de calcul des matrices de concordances est quadratique. Si dans notre cas nous avions besoin de quelques minutes pour calculer des matrices de taille 3000, étendre la base de donnée des musiques à plusieurs dizaine voir centaines de milliers semble déraisonnable.

5 Conclusion

Malgré les limites et les problèmes rencrencontrés, pouvons tout de même affirmer que notre approche a fonctionnée et nous avons obtenu un résultat cohérent. L'approche du problème par la méthode ELECTRE IS n'est probablement pas la plus rapide ni la plus efficace et il serait intéressant d'essayer d'autres approches pour voir si elles donnent des résultats similaires. De plus, le plus grand défaut de notre analyse actuelle est le calcul du score des styles musicaux. Il demande la définition arbitraire d'une matrice de distance et ne renvoie pas de résultats reflétant la proximité réaliste d'une musique avec la playlist. Si une telle analyse venait à être refaite, il serait judicieux de se pencher sur ce critère déterminant dans l'appréciation d'une musique par l'utilisateur.

6 Annexes

6.1 Graphiques

6.1.1 Répartion des musiques utilisées par critère

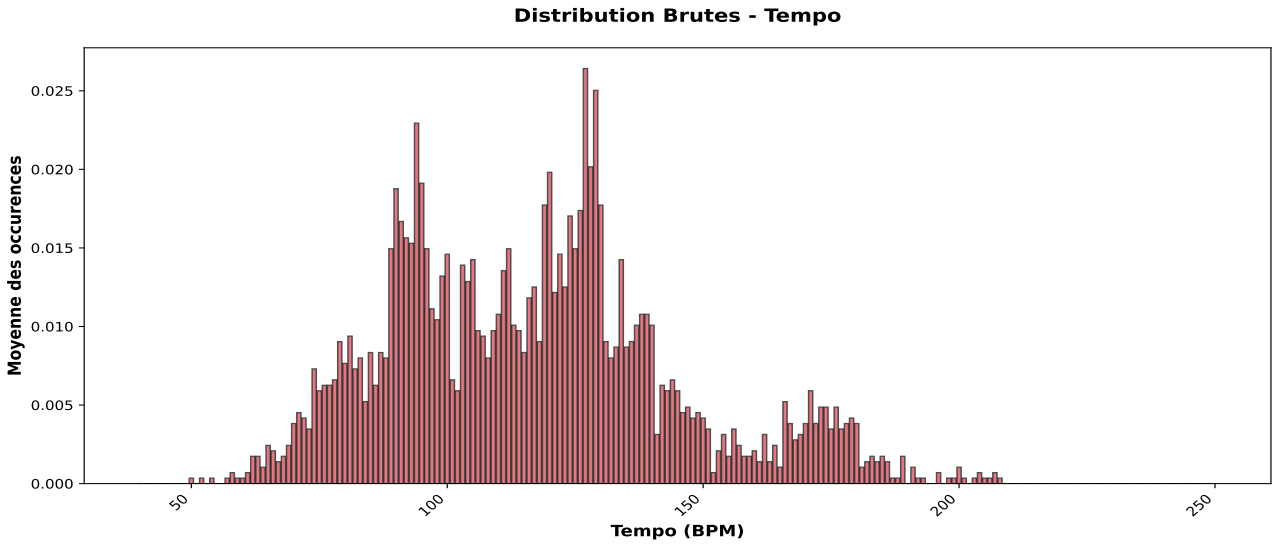


FIGURE 8 – Moyenne des occurrences par tempo des musiques filtrées

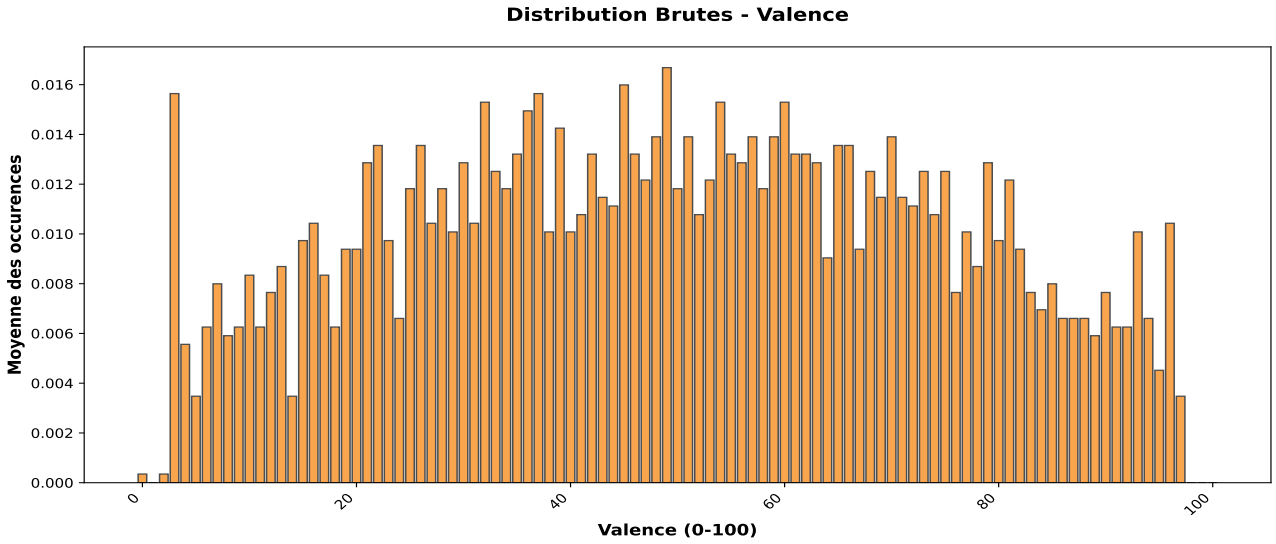


FIGURE 9 – Moyenne des occurrences par valence des musiques filtrées

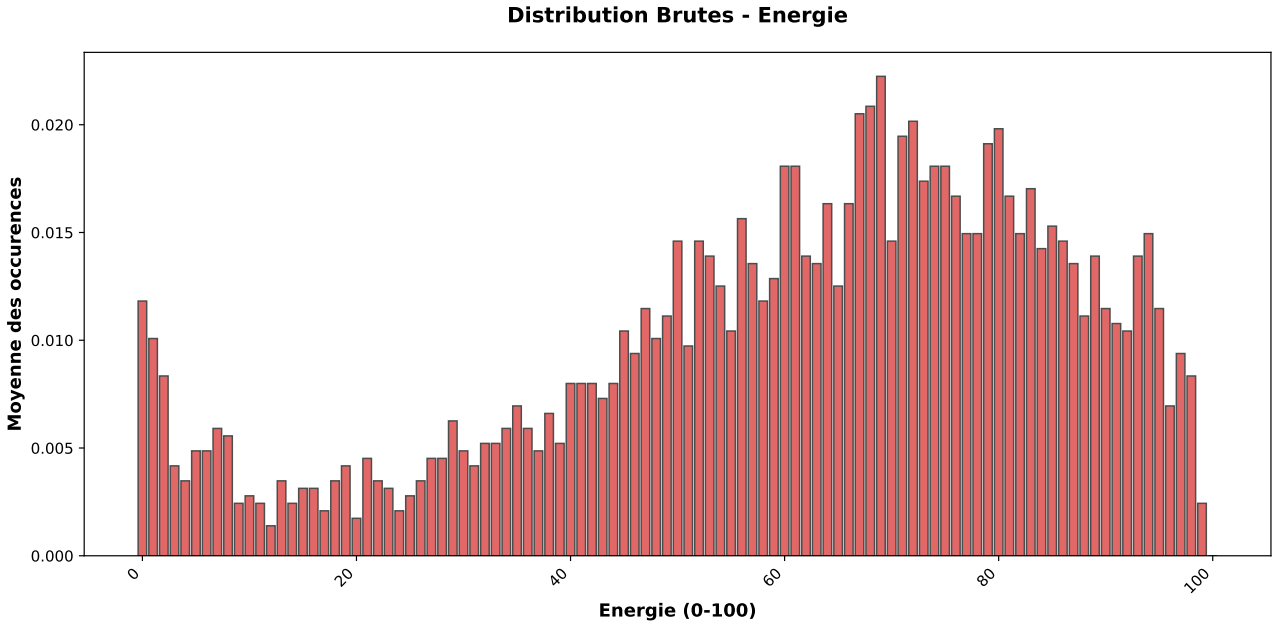


FIGURE 10 – Moyenne des occurrences par énergie des musiques filtrées

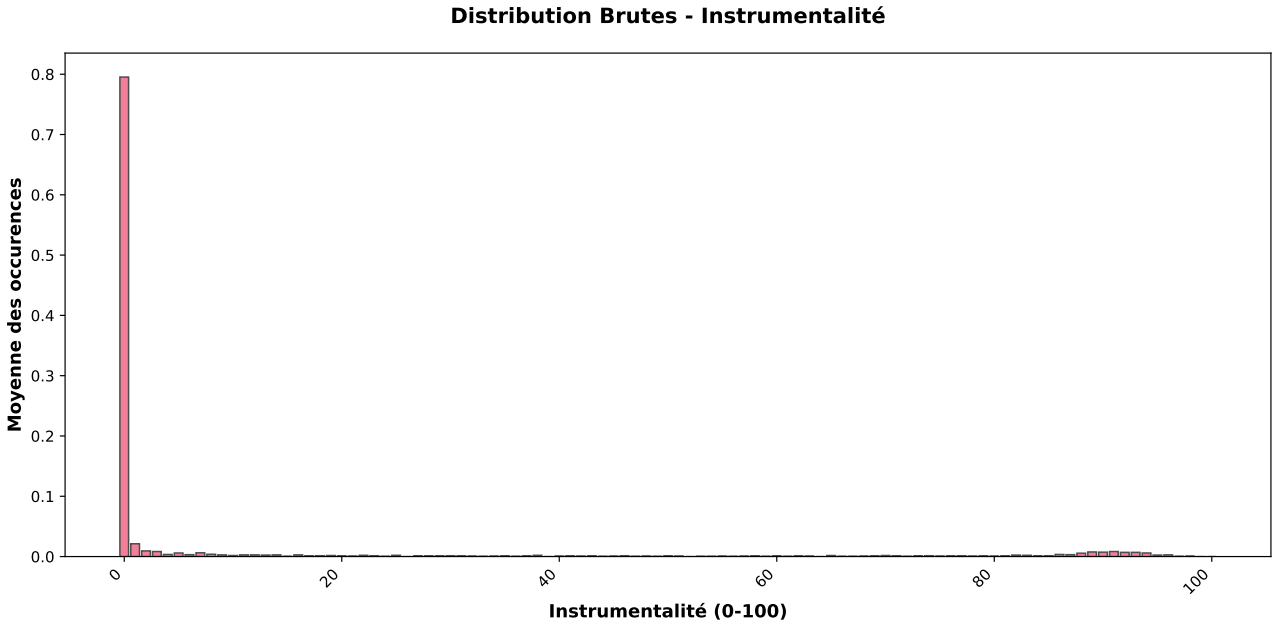


FIGURE 11 – Moyenne des occurrences par instrumentalité des musiques filtrées

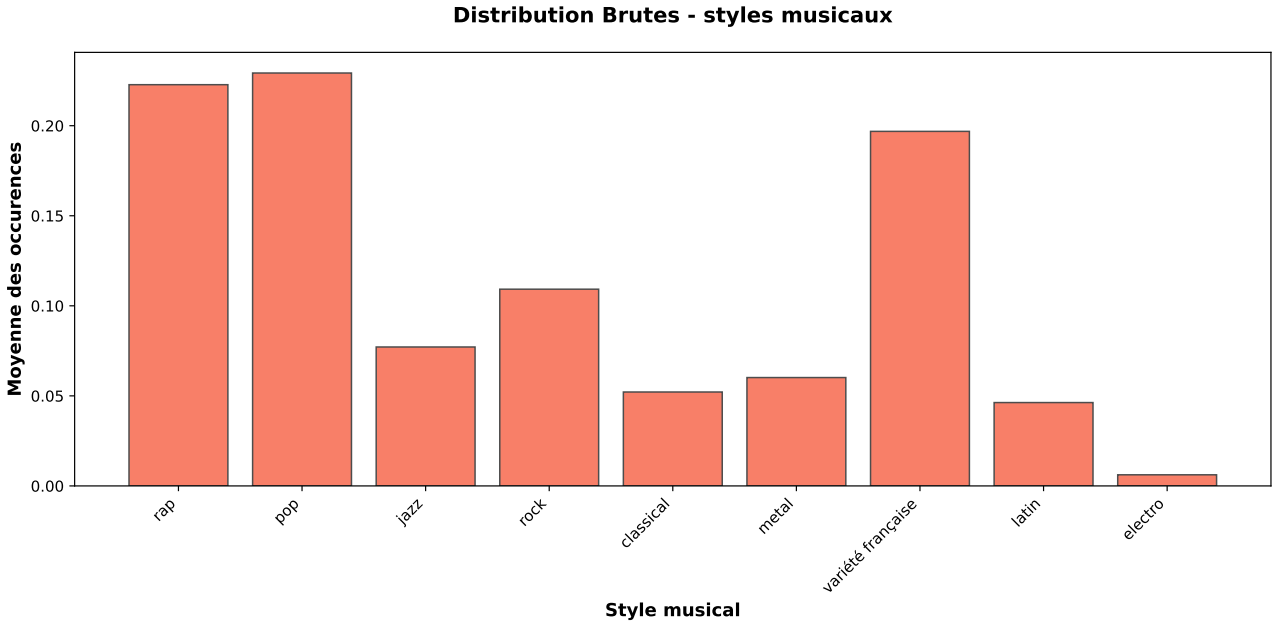


FIGURE 12 – Moyenne des occurrences par genre des musiques filtrées

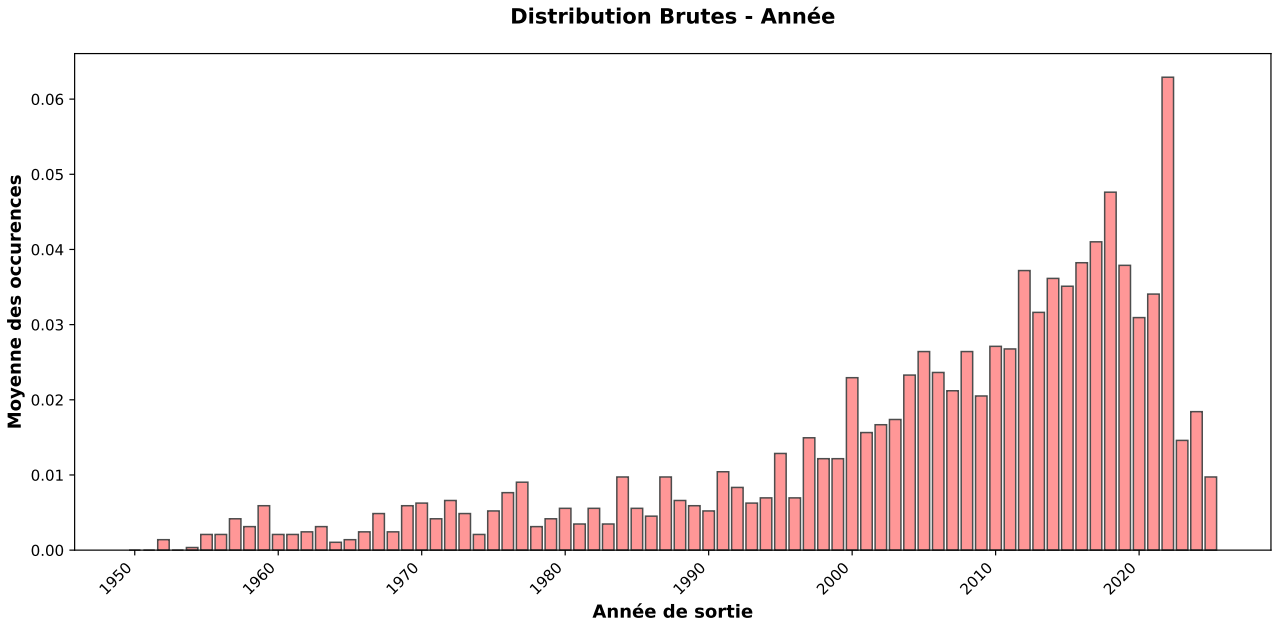


FIGURE 13 – Moyenne des occurrences par année des musiques filtrées

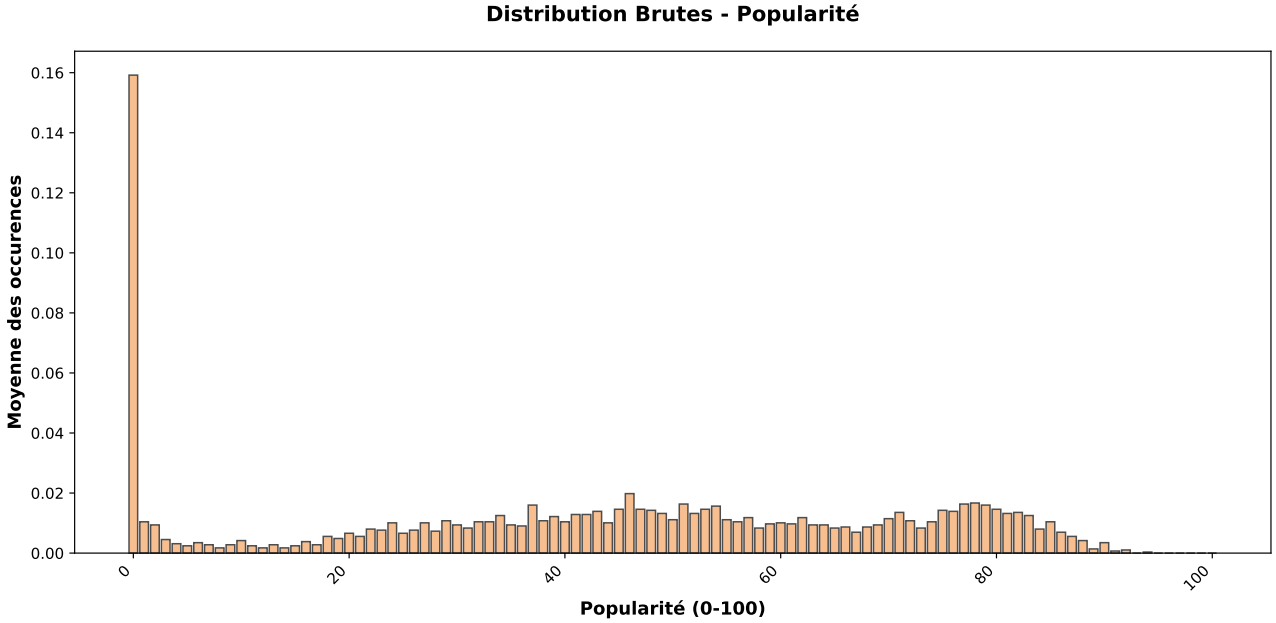


FIGURE 14 – Moyenne des occurrences par popularité des musiques filtrées

Ces graphiques nous apprennent plusieurs choses sur les musiques déjà présentes dans notre base de données, si la valence et l'énergie sont distribuées de manière relativement homogène, d'autres critères comme la popularité ou l'instrumentalité sont extrêmement concentrés. Pour l'instrumentalité, ceci n'a rien de surprenant, la plupart des musiques enregistrés sont issues de styles où la parole prend une part très importante. Pour la popularité nous étions surpris au premier abord, vu des playlists téléchargées qui semblaient contenir une grande majorité de titres célèbres.
Après une rapide analyse, le problème vient de la manière dont les API définissent la popularité, elle dépend principalement du nombre actuel d'écoutes. Ainsi une musique comme *Only Girl (In The World)* de Rihanna a une popularité de 0 alors qu'il s'agit d'une musique mondialement connue. Cela créer un effet ou les musiques se concentrent à 0, puisqu'elle ne peuvent pas descendre en dessous.

6.1.2 Détail du profil de la playlist

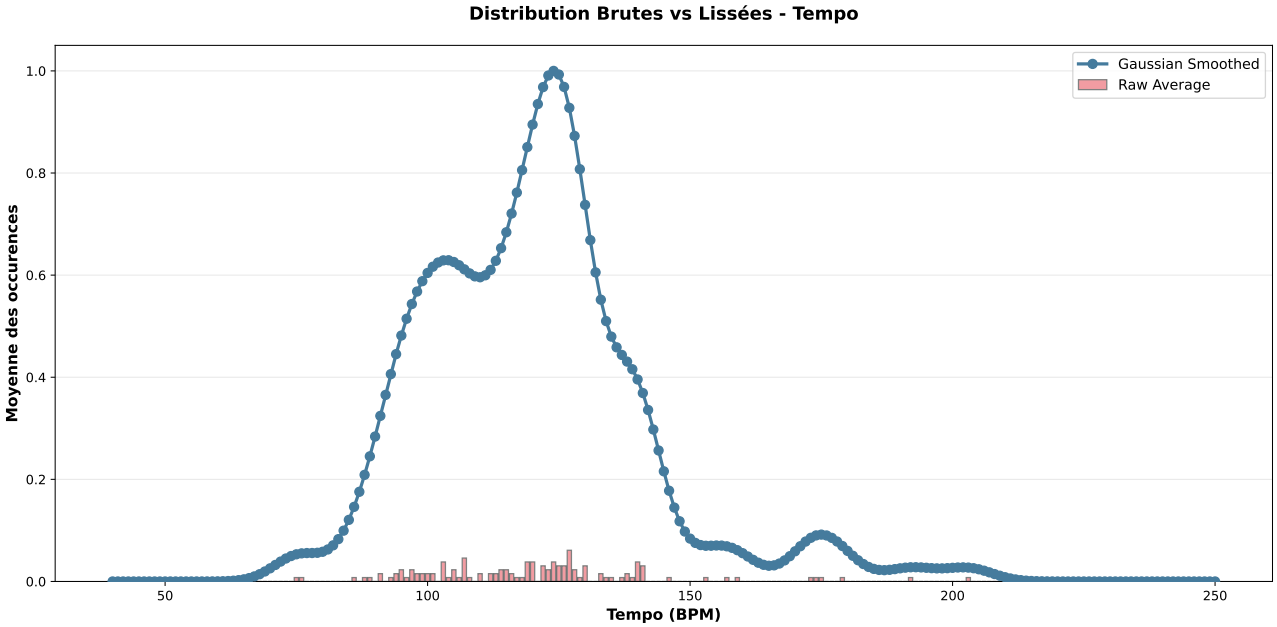


FIGURE 15 – Comparaison entre le profil de la playlist et les valeurs brutes sur le tempo

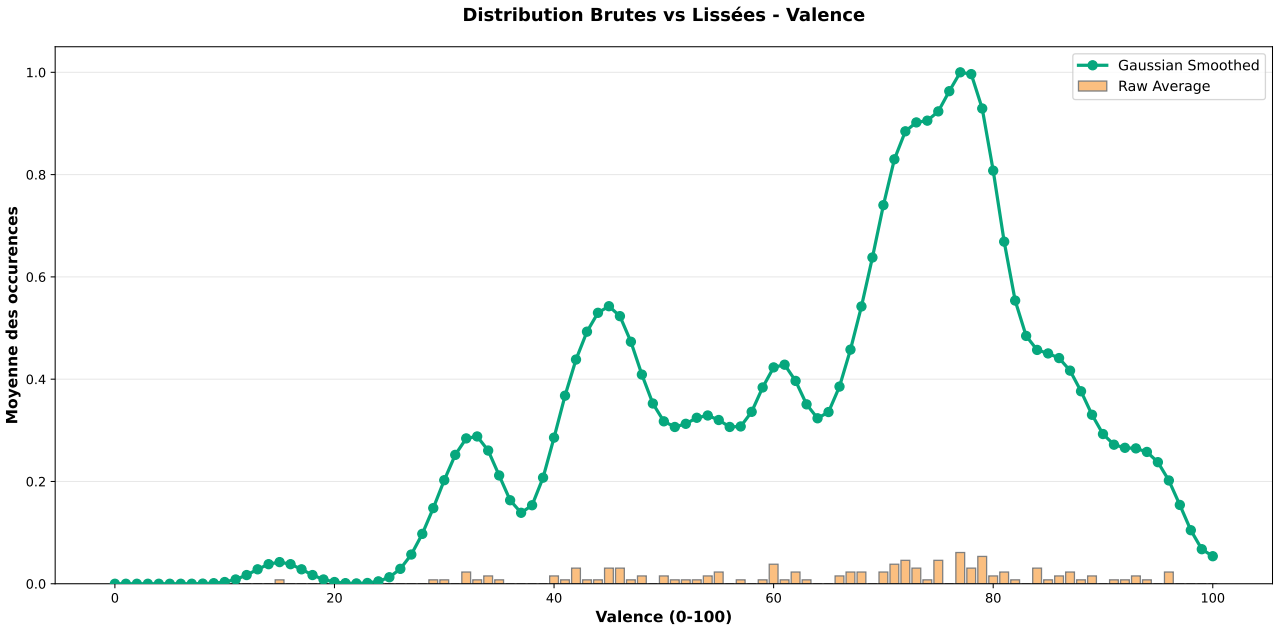


FIGURE 16 – Comparaison entre le profil de la playlist et les valeurs brutes sur la valence

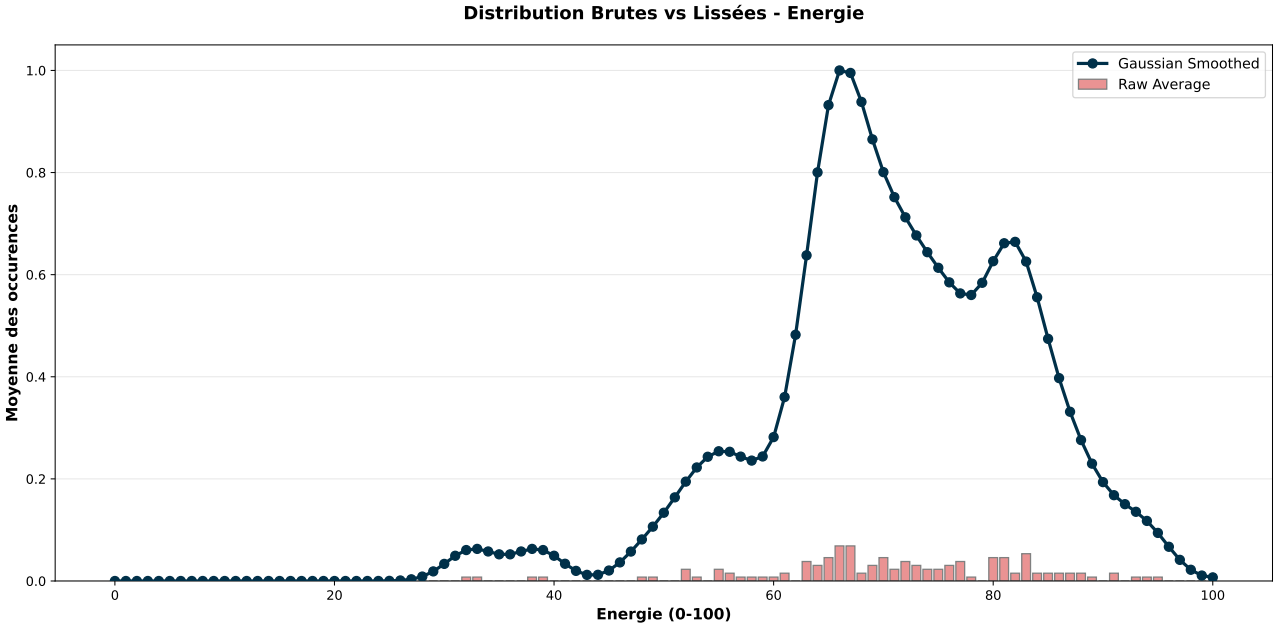


FIGURE 17 – Comparaison entre le profil de la playlist et les valeurs brutes sur l'énergie

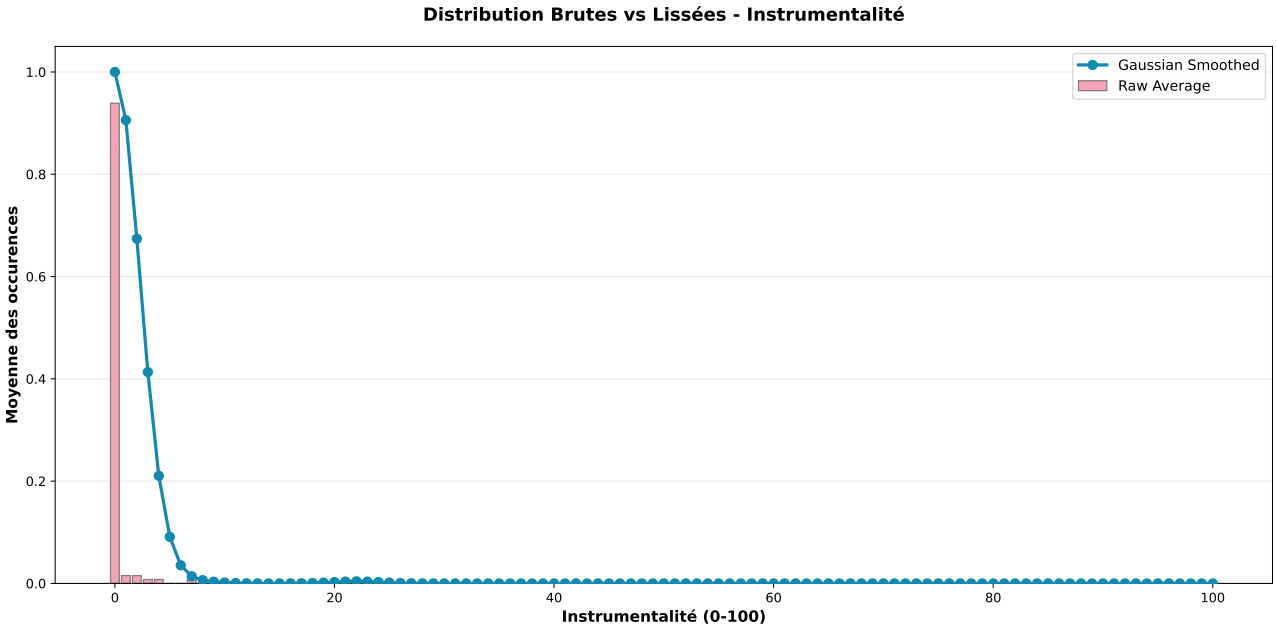


FIGURE 18 – Comparaison entre le profil de la playlist et les valeurs brutes sur l'instrumentalité

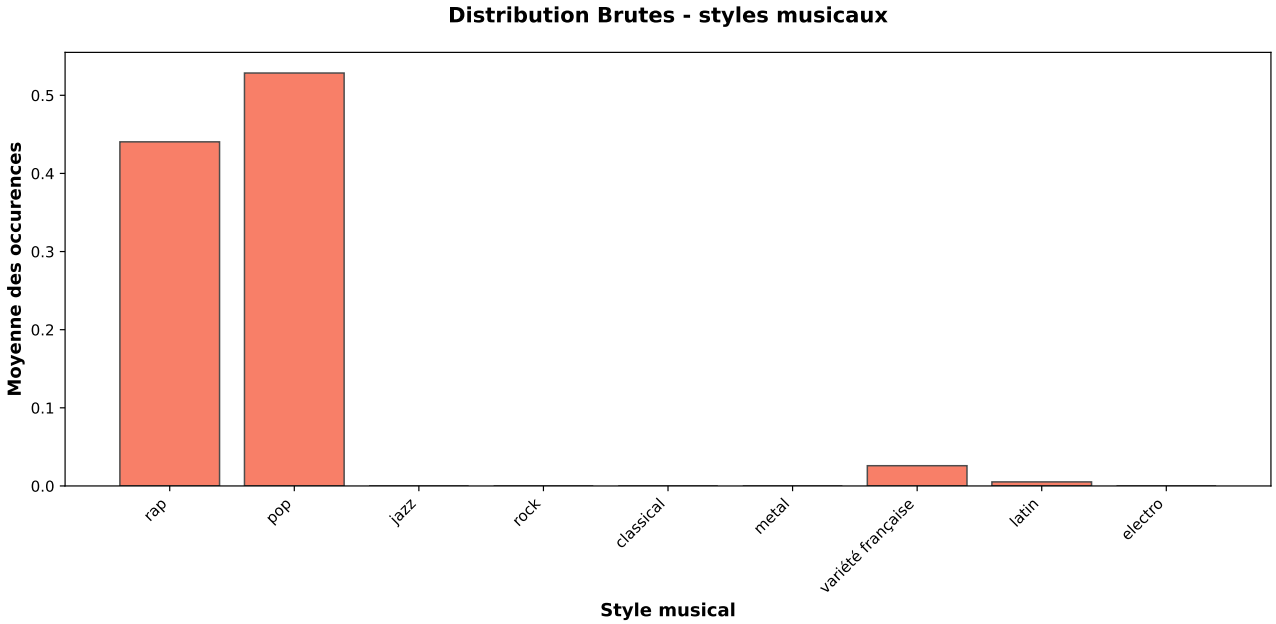


FIGURE 19 – Comparaison entre le profil de la playlist et les valeurs brutes sur le style musical

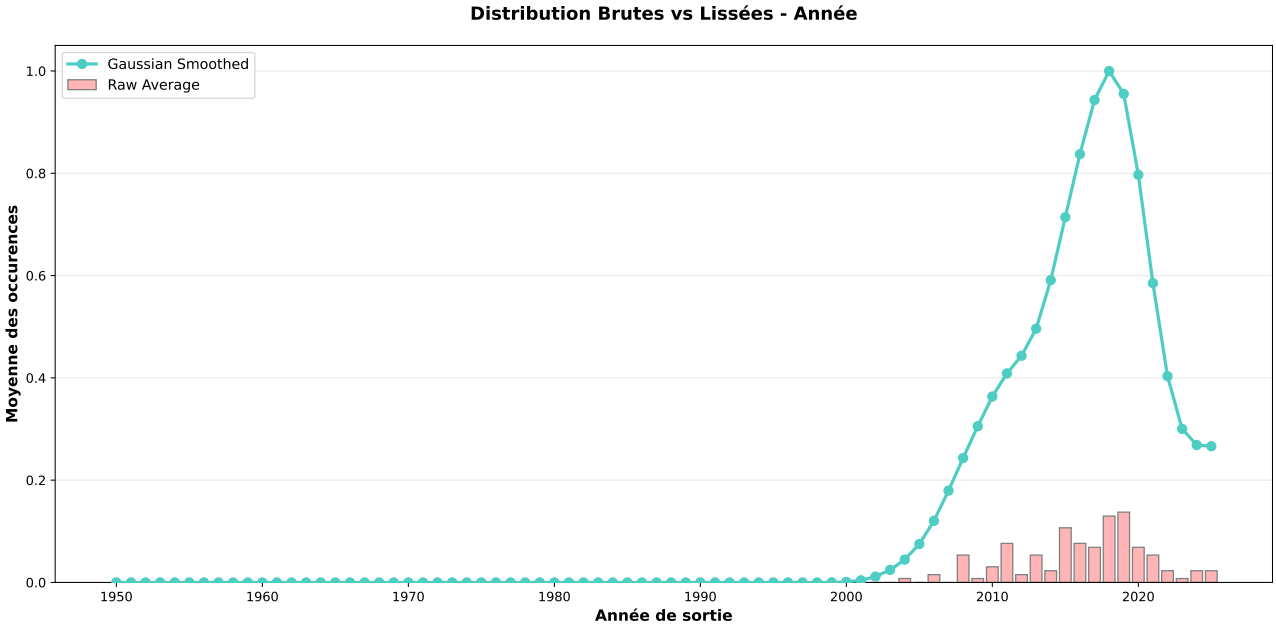


FIGURE 20 – Comparaison entre le profil de la playlist et les valeurs brutes sur l'année de sortie

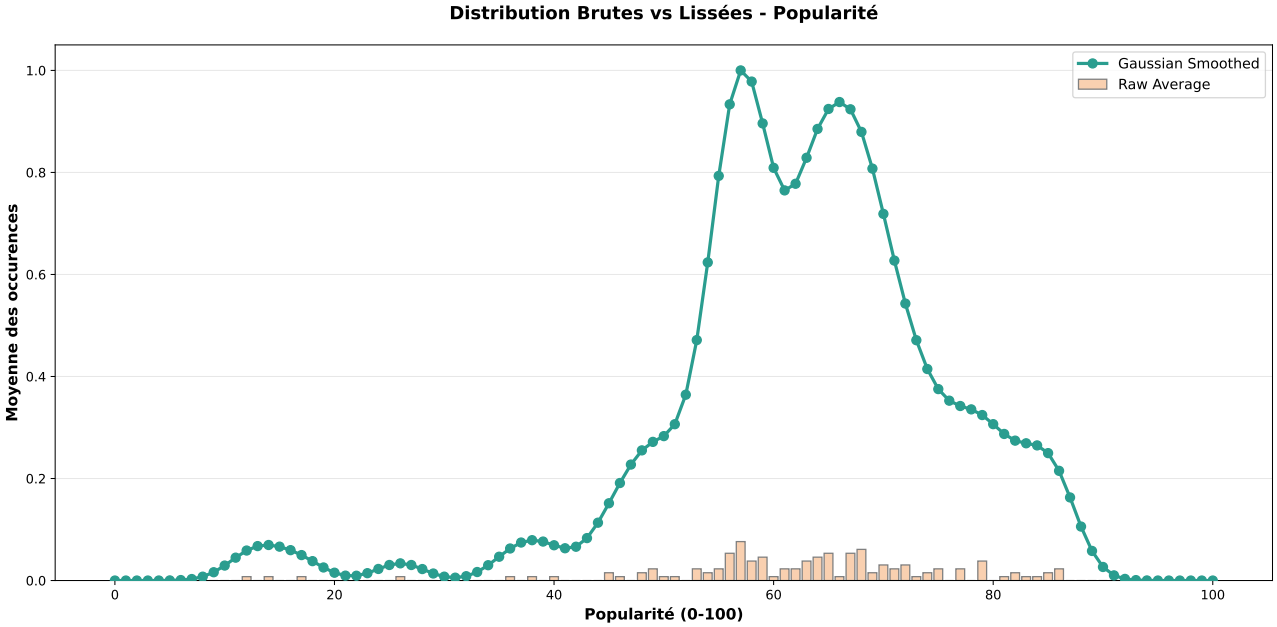


FIGURE 21 – Comparaison entre le profil de la playlist et les valeurs brutes sur la popularité

Ces graphiques nous permettent de bien visualiser le travail effectué entre les données brutes normalisées et le lissage puis l'accentuation des écarts pour créer le profil. Ainsi, nous pouvons clairement distinguer les deux styles principaux qui se dégagent au sein de notre playlist, à savoir le rap et la pop. Nous remarquons également que la plupart des musiques sont récentes et plutôt joyeuses (valence élevée).

6.1.3 Détail de la répartition des scores

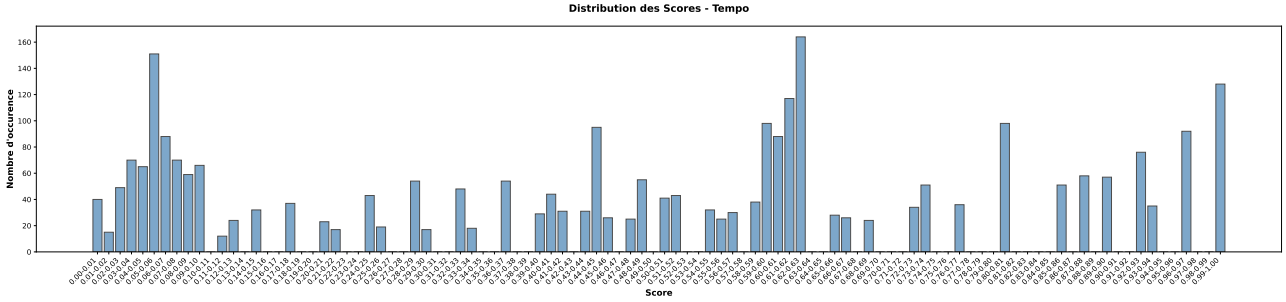


FIGURE 22 – Répartition des scores des musiques filtrées pour le tempo

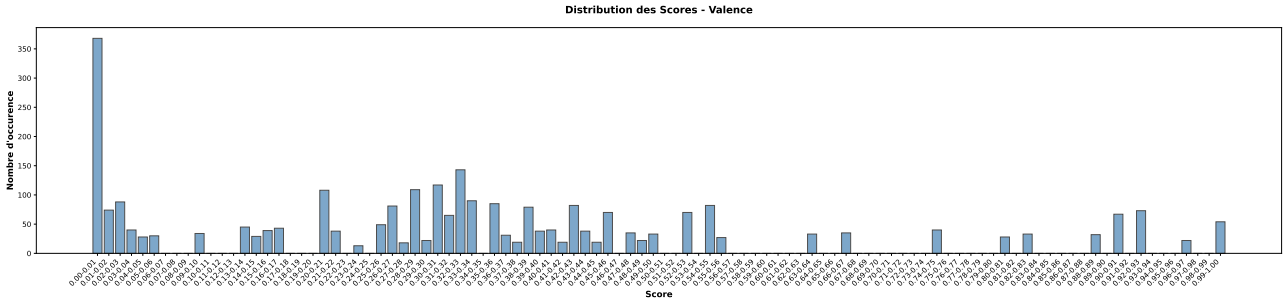


FIGURE 23 – Répartition des scores des musiques filtrées pour la valence

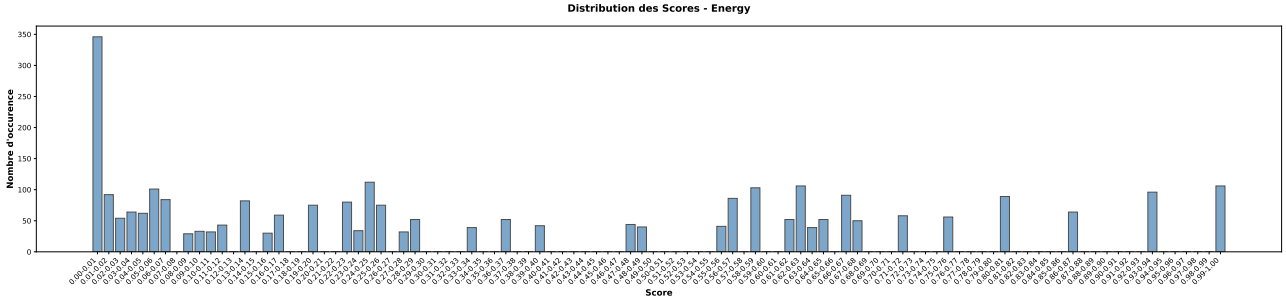


FIGURE 24 – Répartition des scores des musiques filtrées pour l'énergie

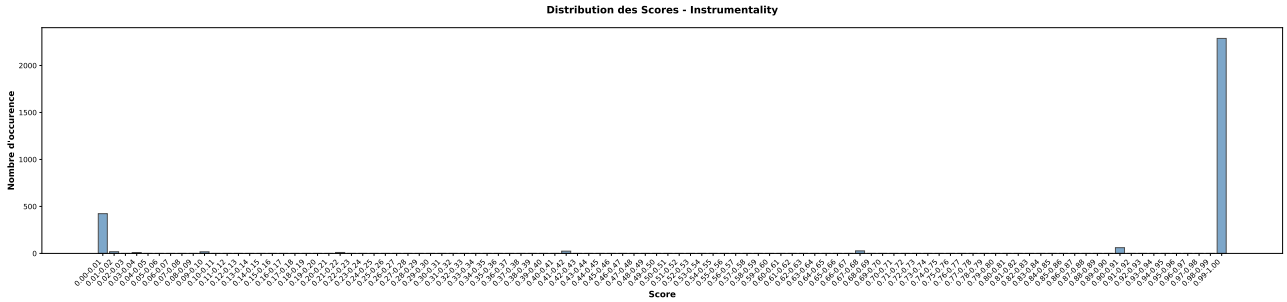


FIGURE 25 – Répartition des scores des musiques filtrées pour l'instrumentalité

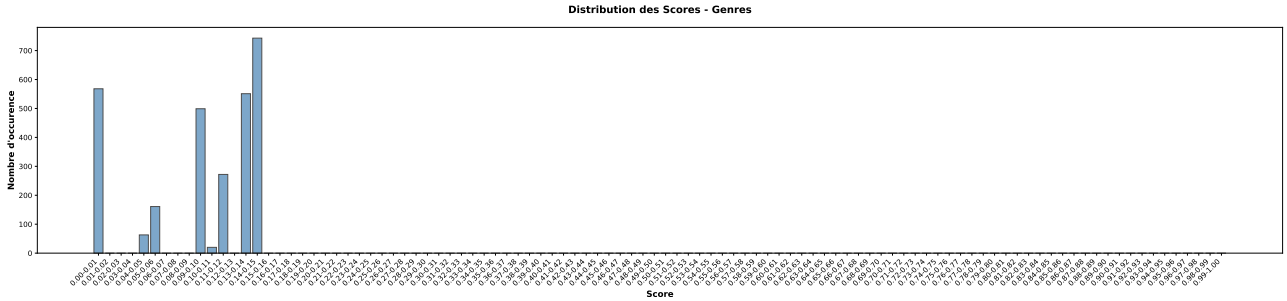


FIGURE 26 – Répartition des scores des musiques filtrées pour le style musical

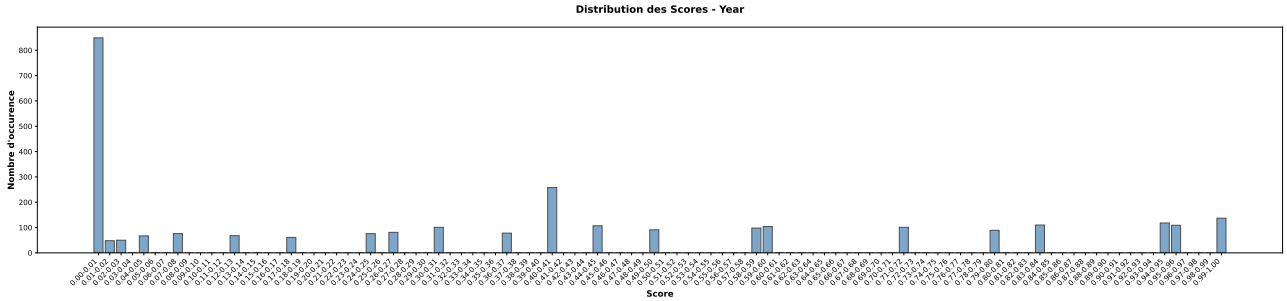


FIGURE 27 – Répartition des scores des musiques filtrées pour l'année

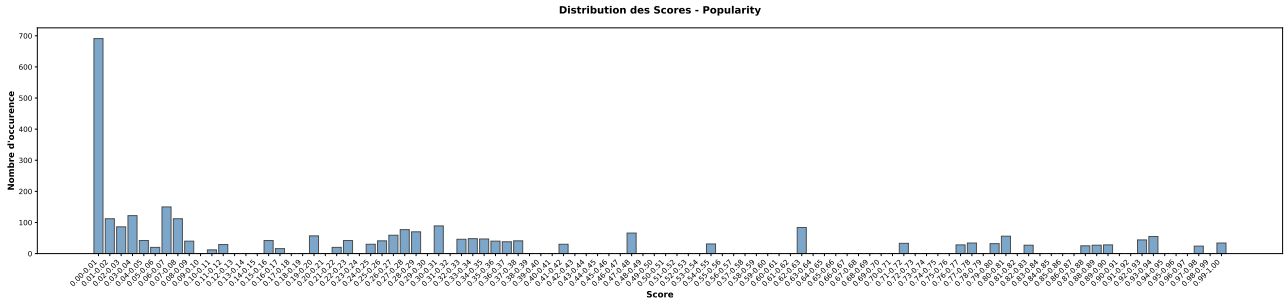


FIGURE 28 – Répartition des scores des musiques filtrées pour la popularité

On remarque que pour la plupart des critères les scores sont bien répartis sur toutes les valeurs, à l'exception de l'instrumentalité et du style musical. Pour l'instrumentalité, cela vient du fait que notre base de données et notre playlist soient en accord, les deux possèdent une grande majorité de musiques chantées, cela se traduit par d'excellents scores pour la plupart des musiques. Pour le style musical, le problème vient de la manière dont on calcule le score. Pour avoir un bon score, la musique et la playlist doivent avoir tous les styles musicaux possibles, ce qui est extremement rare, voire impossible.

6.1.4 Détail des matrices de concordances

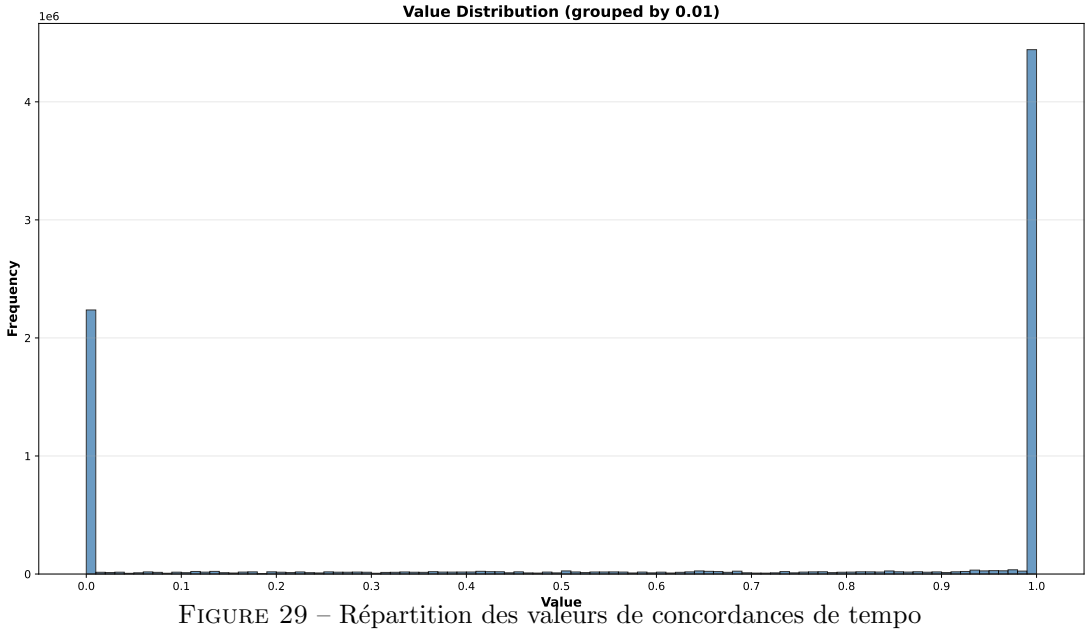


FIGURE 29 – Répartition des valeurs de concordances de tempo

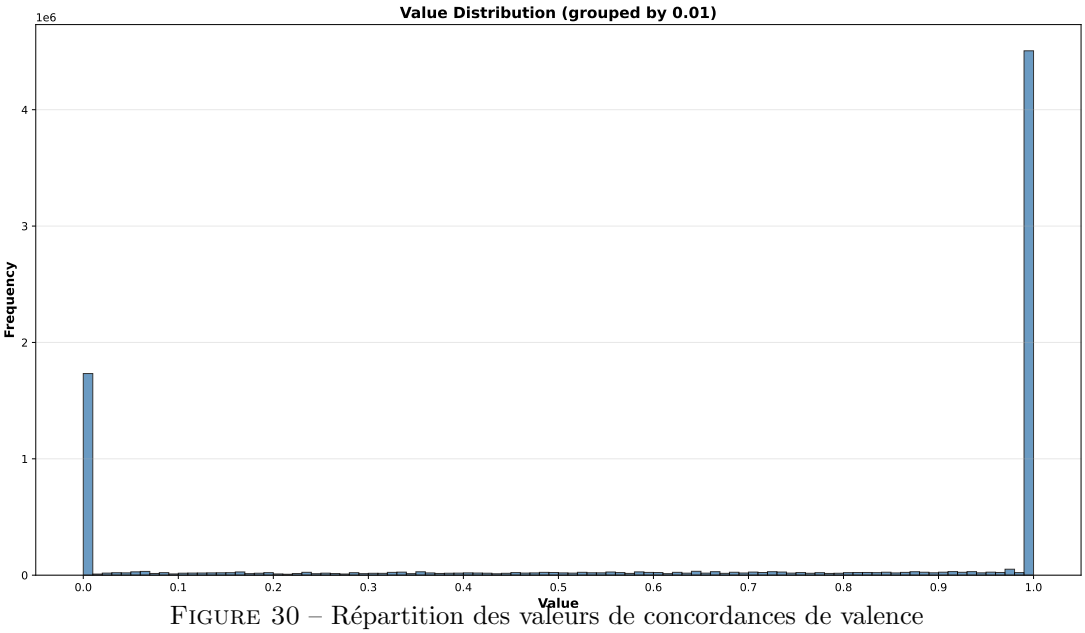


FIGURE 30 – Répartition des valeurs de concordances de valence

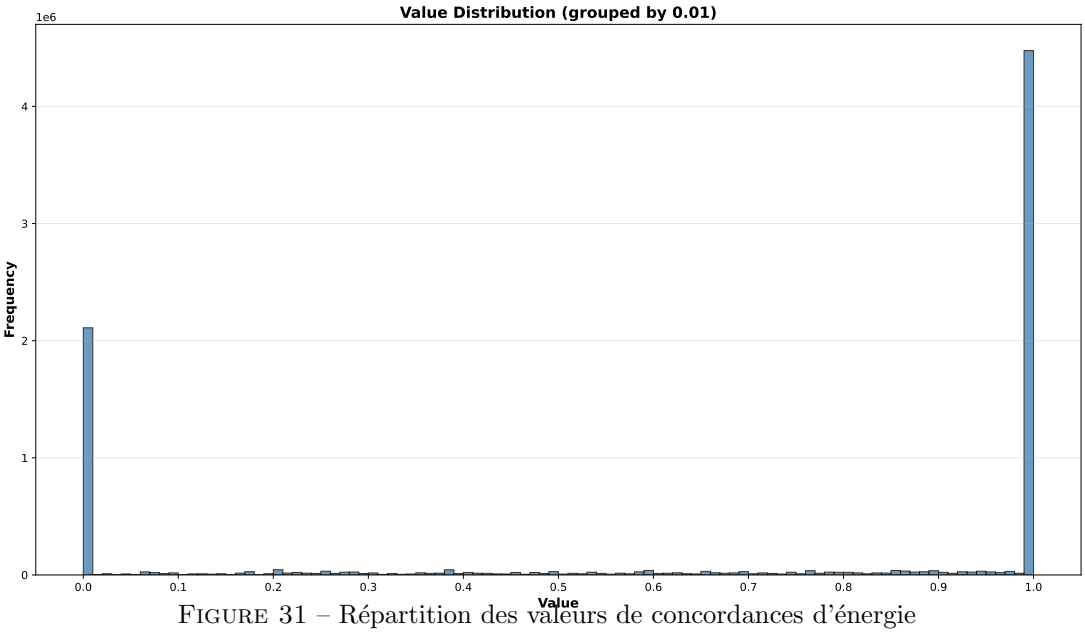


FIGURE 31 – Répartition des valeurs de concordances d'énergie

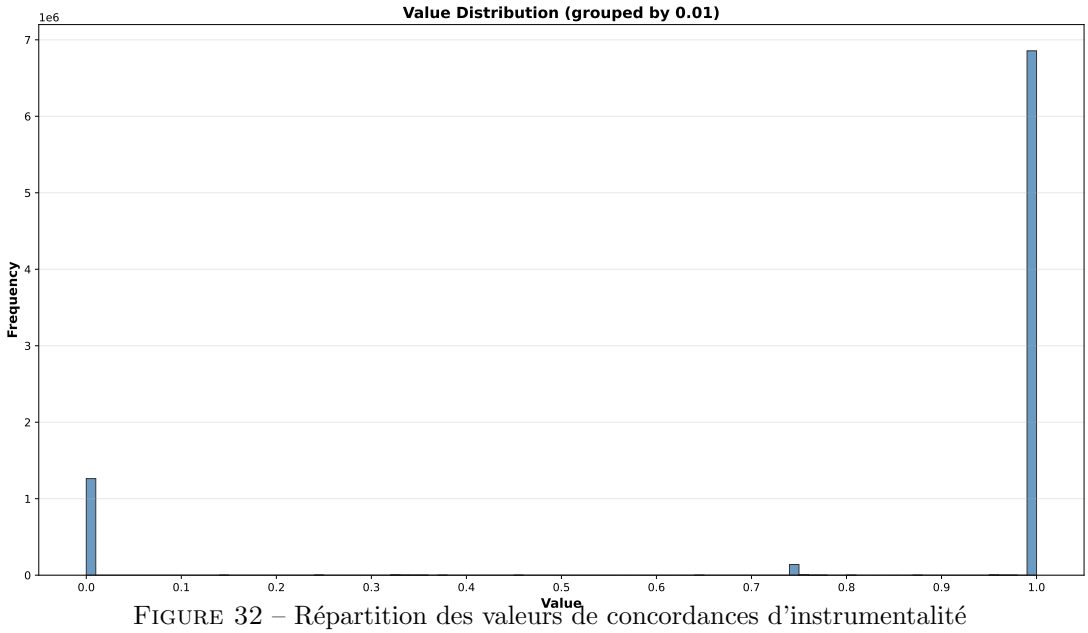


FIGURE 32 – Répartition des valeurs de concordances d'instrumentalité

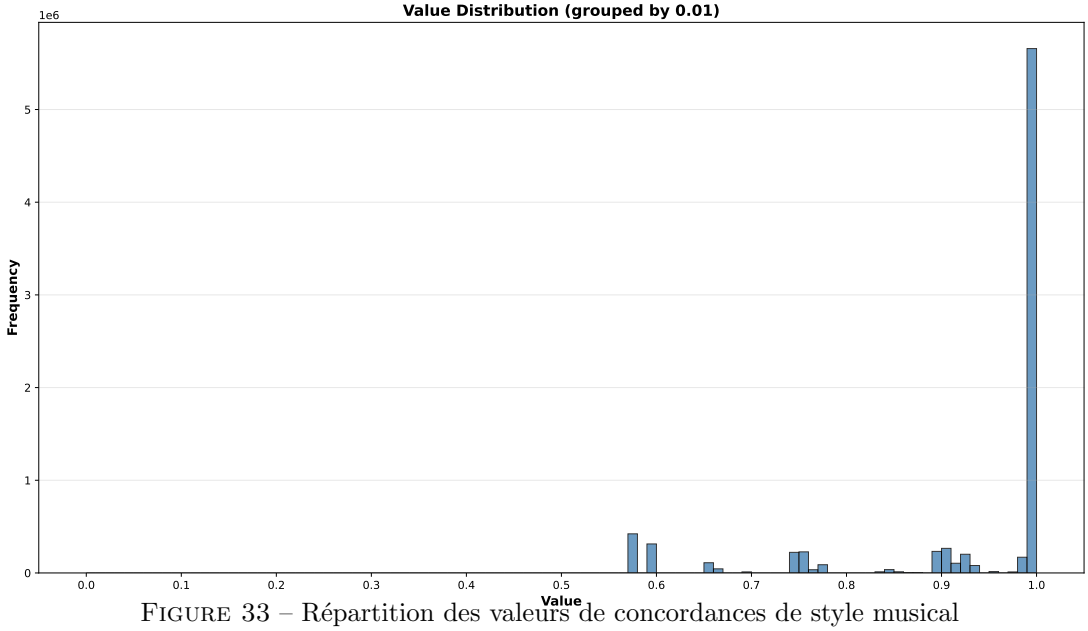


FIGURE 33 – Répartition des valeurs de concordances de style musical

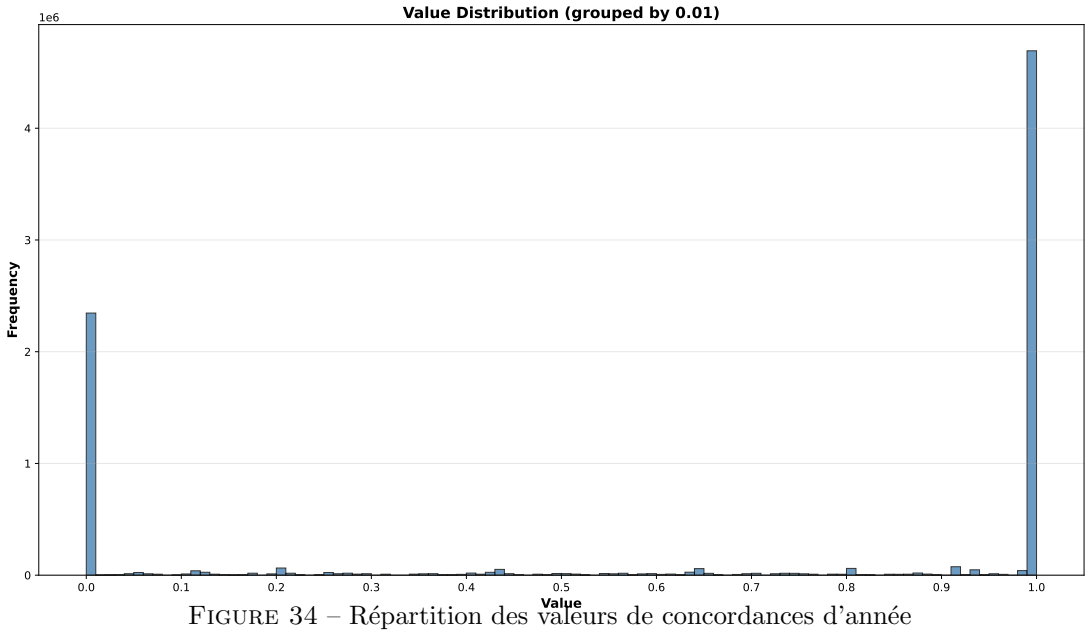


FIGURE 34 – Répartition des valeurs de concordances d'année

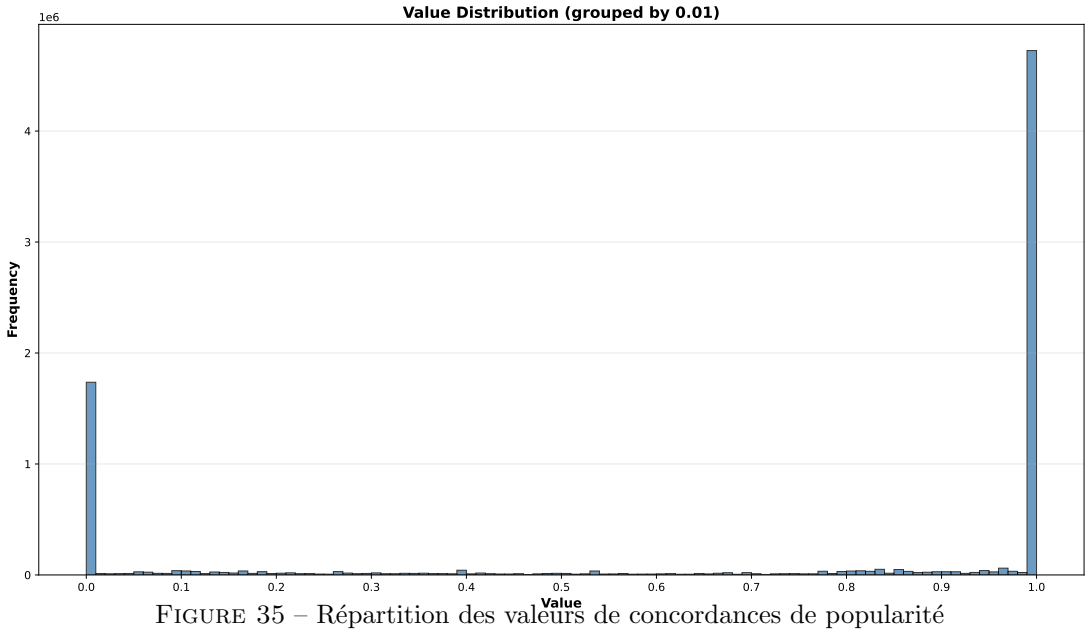


FIGURE 35 – Répartition des valeurs de concordances de popularité

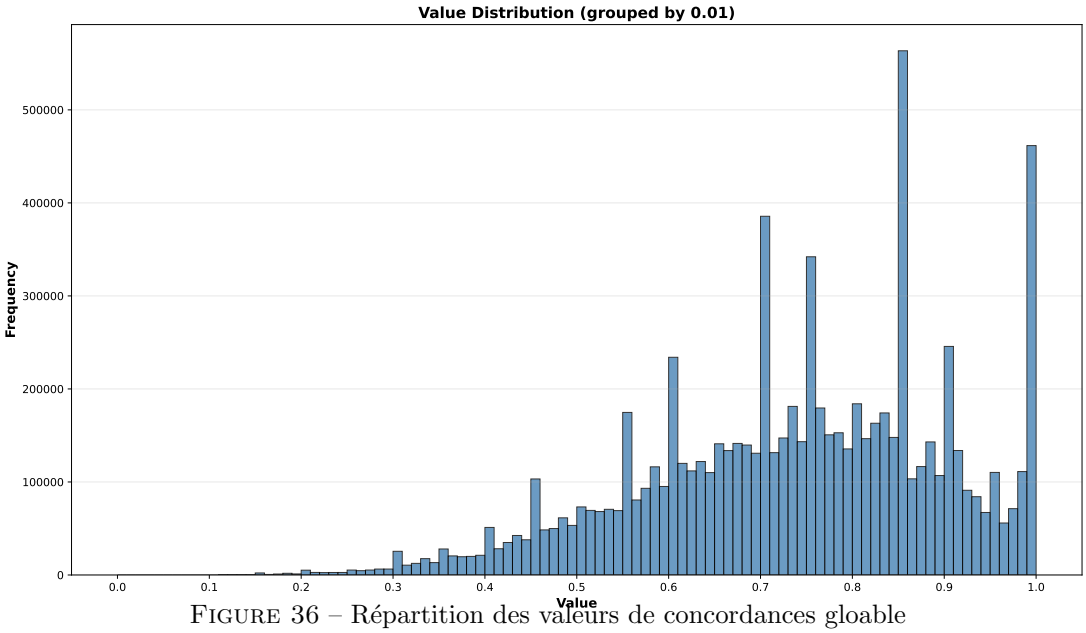


FIGURE 36 – Répartition des valeurs de concordances gloable

On peut remarquer que pour tous les critères, les concordances sont extrêmement marquées à 0 ou à 1 mais cela se lisse pour la matrice globale. On remarque plusieurs pics correspondant à des sommes de poids, ce qui est en parfaite adéquation avec le fait que les concordances des critères soient quasiment binaires.